

Analisi Business Intelligence — VinLiber

Customer Analytics, Clustering e Business Intelligence

Mattia Lombardo & Francesco Colombini

07 maggio 2026

Contents

1	Introduzione e Contesto di Business	3
2	Importazione e Qualità dei Dati	4
2.1	Caricamento dei Dataset	4
2.2	Report di Qualità dei Dati	4
3	Preprocessing e Gestione delle Anomalie	6
3.1	Rilevazione e Trattamento degli Outlier	6
3.2	Imputazione dei Valori Mancanti	7
4	Analisi Esplorativa dei Dati (EDA)	7
4.1	Distribuzione delle Caratteristiche Chimiche	7
4.2	Matrice di Correlazione tra Variabili Chimiche	9
4.3	Scatter Plot Matrix	10
5	Costruzione del Dataset Unificato	11
5.1	Join tra Vini e Recensioni	11
5.2	Correlazioni nel Dataset Unificato	11
6	Analisi delle Valutazioni	13
6.1	Top Vini per Valutazione Media	13
6.2	Segmentazione per Fascia d'Età	14
6.3	Boxplot delle Valutazioni per Fascia d'Età	15

7	Test Statistici sulle Fasce d'Età	16
7.1	ANOVA per fascia d'età	16
7.2	ANOVA per nazionalità	18
7.3	Confronti Post-Hoc (Tukey HSD)	19
7.4	Diagnostica del Modello ANOVA	20
8	Regressione Lineare e Multicollinearità	21
8.1	Modello Completo	21
8.2	Verifica della Multicollinearità (VIF)	22
8.3	Selezione del Modello con Stepwise AIC	23
9	Graduatorie dei Vini per Fascia d'Età	24
10	Clustering dei Vini	26
10.1	Standardizzazione e Selezione delle Feature	26
10.2	Selezione del Numero Ottimale di Cluster (k) per i vini	27
10.3	Clustering Gerarchico	29
10.4	Heatmap Cluster Vini	31
10.5	Profilazione dei Cluster di Vini	33
11	Clustering dei Consumatori (Recensori)	33
11.1	Preparazione delle Feature dei Consumatori	33
11.2	Selezione del k Ottimale per i Consumatori	34
11.3	Profilazione dei Cluster di Consumatori	36
12	Analisi Integrata: Cluster di Vini e Preferenze dei Consumatori	37
13	Visualizzazioni di Sintesi per la Dashboard	38
14	Export per Dashboard	40
14.1	Preparazione dei File di Export	40
14.2	Riepilogo delle Variabili Chiave per la Dashboard	41
15	Conclusioni e Insight Strategici	41

1 Introduzione e Contesto di Business

Questa analisi supporta la strategia commerciale di una cantina focalizzata sulla **coltivazione biologica**, la **produzione etica** e il **valore sociale**. La viticoltura biologica si distingue da quella convenzionale per l'assenza di pesticidi di sintesi e per pratiche di conservazione del suolo che influenzano direttamente la composizione chimica del vino. Comprendere questi profili chimici, e come si traducono in preferenze di consumatori differenti, è il fondamento di una strategia di posizionamento autentica e sostenibile.

L'analisi si articola in quattro fasi principali:

1. **Qualità dei Dati e Preprocessing:** pulizia robusta e rilevazione di anomalie.
2. **EDA Avanzata:** esplorazione delle correlazioni tra chimica del vino e preferenze demografiche.
3. **Clustering:** segmentazione di vini e consumatori per profili omogenei.
4. **Export per Dashboard:** produzione di file strutturati pronti per Power BI / Tableau.

2 Importazione e Qualità dei Dati

2.1 Caricamento dei Dataset

Il primo passo di qualsiasi pipeline è verificare l'integrità dei dati prima di qualsiasi trasformazione. Per una cantina biologica, dove ogni lotto ha caratteristiche chimiche uniche legate alla stagione e al territorio, la presenza di duplicati o record orfani comprometterebbe la qualità degli insight estratti.

2.2 Report di Qualità dei Dati

Rilevare in modo esplicito i problemi di qualità, duplicati, chiavi orfane, valori mancanti, consente di documentare il livello di affidabilità dell'analisi e di comunicarlo in modo trasparente agli stakeholder aziendali.

Inoltre, per comprendere meglio la distribuzione dei dati è necessario un riassunto statistico compatto per ogni variabile: range, quantili, tasso di completezza e deviazione standard. Questo permette di individuare immediatamente le variabili con distribuzioni anomale o con valori scorretti prima di procedere con qualsiasi trasformazione.

=== SINTESI STATISTICA: VINI ===

Table 1: Data summary

Name	vini
Number of rows	20
Number of columns	14
Column type frequency:	
character	2
factor	1
numeric	11
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
wine_id	0	1	1	2	0	20	0
id_vino	0	1	9	26	0	20	0

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
type	0	1	FALSE	2	R: 12, W: 8

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100
fixed.acidity	0	1	8.25	1.47	5.47	6.91	8.15	9.67	10.21
volatile.acidity	0	1	0.48	0.20	0.16	0.36	0.49	0.57	0.97
citric.acid	0	1	0.29	0.16	0.00	0.21	0.32	0.39	0.60
residual.sugar	0	1	4.34	2.41	1.12	2.40	3.79	5.65	9.55
chlorides	0	1	0.06	0.03	0.03	0.05	0.06	0.08	0.11
free.sulfur.dioxide	0	1	27.72	12.81	10.64	18.22	26.21	31.47	61.44
total.sulfur.dioxide	0	1	102.82	70.47	27.98	43.89	73.84	154.07	294.11
density	0	1	1.00	0.00	0.99	1.00	1.00	1.00	1.00
pH	0	1	3.33	0.14	3.10	3.25	3.31	3.40	3.74
sulphates	0	1	0.57	0.13	0.24	0.49	0.58	0.63	0.79
alcohol	0	1	10.66	1.43	8.50	9.91	10.49	11.24	13.55

=== SINTESI STATISTICA: RECENSIONI ===

Table 2: Data summary

Name	recensioni
Number of rows	2000
Number of columns	5
Column type frequency:	
character	1
factor	2
numeric	2
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
wine_id	0	1	1	2	0	20	0

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
sesso	0	1	FALSE	2	M: 1173, F: 827

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
nazionalita	0	1	FALSE	4	Ita: 851, USA: 503, Fra: 350, Alt: 296

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100
età	0	1	46.32	15.66	20	29	54.0	60.0	69
valutazione	0	1	6.61	1.02	3	6	6.5	7.5	9

Il report conferma un dataset in ottime condizioni: nessun duplicato, nessun valore mancante e perfetta coerenza referenziale tra i due file. Il catalogo vini comprende **20 etichette** con 14 variabili ciascuna, mentre il dataset di recensioni conta **2.000 osservazioni** su 5 colonne. L'integrità referenziale è completa: ogni vino ha almeno una recensione e ogni recensione è collegata a un vino esistente nel catalogo. Questa pulizia di partenza garantisce che tutti i 20 vini partecipino alle analisi successive senza introdurre distorsioni da dati mancanti o disallineamenti di chiave.

Per i vini, le variabili chimiche mostrano distribuzioni plausibili: l'alcol medio è 10.66% (range 8.5–13.55%), il pH medio è 3.33 e il residuo zuccherino medio di 4.34 g/L è coerente con vini secchi da agricoltura biologica. Il dataset di recensioni presenta un'età media dei recensori di 46 anni (range 20–69), con una predominanza maschile (M: 58.7%, F: 41.3%) e una maggioranza di nazionalità italiana (42.6%), seguita da americana (25.2%), francese (17.5%) e altre (14.8%). La valutazione media complessiva è 6.61 su una scala da 3 a 9, con una deviazione standard di 1.02 che segnala una dispersione moderata e ben utilizzabile per l'analisi segmentata.

3 Preprocessing e Gestione delle Anomalie

3.1 Rilevazione e Trattamento degli Outlier

Gli outlier nei parametri chimici del vino (es. acidità volatile molto elevata, residuo zuccherino anomalo) non sono necessariamente errori: possono riflettere vini di nicchia con profili estremi inferiori al 1° percentile e superiori al 99°.

```
## fixed.acidity           → outlier corretti: basso=1, alto=1
## volatile.acidity       → outlier corretti: basso=0, alto=1
## citric.acid            → outlier corretti: basso=1, alto=1
## residual.sugar         → outlier corretti: basso=1, alto=1
## chlorides              → outlier corretti: basso=0, alto=0
## free.sulfur.dioxide    → outlier corretti: basso=1, alto=1
## total.sulfur.dioxide   → outlier corretti: basso=1, alto=1
## density                → outlier corretti: basso=0, alto=0
## pH                     → outlier corretti: basso=1, alto=1
## sulphates              → outlier corretti: basso=1, alto=1
## alcohol                → outlier corretti: basso=1, alto=1
```

Il trattamento ha interessato, in modo simmetrico, quasi tutte le variabili chimiche (1 outlier basso e 1 alto per la maggior parte di esse). Solo `chlorides` e `density` risultano prive di valori estremi da correggere, il che indica distribuzioni già ben concentrate intorno alla mediana.

3.2 Imputazione dei Valori Mancanti

Per le variabili chimiche continue si utilizza l'imputazione con la mediana anziché la media: la mediana è robusta rispetto agli outlier residui e non altera la distribuzione complessiva. Questa scelta è particolarmente indicata per dataset con code asimmetriche e garantisce che il clustering successivo non sia distorto da valori imputati non rappresentativi.

```
## NA prima dell'imputazione: 0
## NA dopo l'imputazione:      0
```

Come atteso dalla fase di controllo qualità, il dataset non presentava valori mancanti nelle variabili chimiche: il conteggio rimane 0 sia prima che dopo l'imputazione. Questo passo è incluso come salvaguardia procedurale, indispensabile in qualsiasi pipeline di produzione per gestire correttamente futuri aggiornamenti del catalogo che potrebbero contenere misurazioni parziali.


4 Analisi Esplorativa dei Dati (EDA)

4.1 Distribuzione delle Caratteristiche Chimiche

I vini biologici tendono a presentare livelli di solfiti più bassi rispetto ai convenzionali, poiché la certificazione biologica limita l'uso di SO₂ aggiunta. Visualizzare la distribuzione di ciascuna variabile chimica per tipologia di vino permette di verificare empiricamente questo posizionamento e di comunicarlo con dati oggettivi.

Distribuzione delle Caratteristiche Chimiche per Tipologia di Vino


Ogni pannello mostra la distribuzione di una variabile chimica, distinta per tipo



L'istogramma mostra chiaramente le differenze di composizione chimica tra vini rossi (R, bordeaux) e bianchi (W, ocra). I vini bianchi presentano valori di `free.sulfur.dioxide` e `total.sulfur.dioxide` sensibilmente più alti rispetto ai rossi — coerente con la pratica enologica che richiede maggiori dosi protettive nei bianchi — mentre i rossi mostrano `fixed.acidity` e `volatile.acidity` più elevate. Variabili come `alcohol` e `pH` presentano distribuzioni simili tra le due tipologie, confermando che il processo biologico influisce principalmente sulla gestione dei solfiti e dell'acidità, non sul tenore alcolico di base. Questo pattern è un argomento comunicativo forte per la cantina: i bianchi biologici garantiscono protezione con solfiti ancora moderati, i rossi puntano su acidità naturale come fattore di conservazione.

4.2 Matrice di Correlazione tra Variabili Chimiche

La matrice di correlazione è uno strumento diagnostico fondamentale prima del clustering: variabili altamente correlate (come `free.sulfur.dioxide` e `total.sulfur.dioxide`) portano informazione ridondante e possono distorcere la distanza euclidea usata da k-means. Identificarle in anticipo consente di costruire un modello più preciso e interpretabile.




La matrice di correlazione rivela tre pattern rilevanti per le scelte di modellazione successive. La coppia `free.sulfur.dioxide` / `total.sulfur.dioxide` mostra la correlazione positiva più alta (0.58), confermando che le due misure catturano in parte la stessa dimensione chimica e potrebbero essere aggregate in una variabile sintetica per ridurre la ridondanza nel clustering. La coppia `fixed.acidity` / `residual.sugar` presenta anch'essa una correlazione positiva rilevante (0.68), mentre `alcohol` e `density` mostrano la correlazione negativa più marcata (-0.23), coerente con il principio fisico per cui l'alcol abbassa la densità del liquido. Nessuna coppia supera la soglia critica

di 0.80 che richiederebbe un trattamento obbligatorio prima della regressione, ma le correlazioni moderate identificate giustificano l'analisi VIF condotta nella sezione dedicata alla regressione lineare.

4.3 Scatter Plot Matrix

La visualizzazione a matrice di dispersione, con rette di regressione lineare sovrapposte, rivela relazioni non lineari che la sola correlazione di Pearson non cattura, come l'eventuale effetto a U dell'acidità sulla valutazione. Costituisce un complemento visivo alla matrice di correlazione numerica e aiuta a individuare cluster naturali già nella fase esplorativa.



La scatter matrix conferma ed arricchisce quanto emerso dalla matrice di correlazione. Nella diagonale, le distribuzioni univariate mostrano che la maggior parte delle variabili presenta una forma unimodale, con `total.sulfur.dioxide` e `free.sulfur.dioxide` leggermente asimmetriche verso

destr, fenomeno atteso in vini biologici dove l'uso di SO è controllato ma non assente. Nei pannelli off-diagonali, la retta di regressione tra `fixed.acidity` e `residual.sugar` ha pendenza positiva e visibile, rafforzando la correlazione numerica già rilevata (0.68). Il pannello `alcohol` vs `density` mostra la relazione inversa più netta visivamente, confermando che questo legame fisico è strutturalmente presente anche in un catalogo di soli 20 vini. La scatter matrix non evidenzia cluster visivamente separati nelle variabili bidimensionali, suggerendo che la segmentazione richiederà l'intero spazio multidimensionale, obiettivo del clustering formale nelle sezioni successive.

5 Costruzione del Dataset Unificato

5.1 Join tra Vini e Recensioni

Il join interno (inner join) garantisce che solo i vini con almeno una recensione, e solo le recensioni associate a un vino nel catalogo, entrino nelle analisi successive. Questo preserva la coerenza referenziale ed è la scelta più conservativa per un dataset destinato a insight di business.


```
## Dimensione dataset unificato: 2000 righe x 19 colonne
```

Il dataset unificato conta **2.000 righe** per **19 colonne**, confermando che tutte le recensioni hanno trovato la corrispondenza nel catalogo vini. Ogni riga rappresenta una singola recensione arricchita con le 11 caratteristiche chimiche del vino valutato e con le variabili demografiche del recensore (età, sesso, nazionalità). Questo formato long è la struttura ideale per le analisi di regressione, clustering e cross-segmentazione che seguono.

5.2 Correlazioni nel Dataset Unificato

Includere `eta` e `valutazione` nella matrice di correlazione permette di rispondere alla domanda chiave di business: le caratteristiche chimiche del vino che “piacciono di più” dipendono dall'età del consumatore? Questa analisi orienta sia la formulazione dei prodotti sia la segmentazione delle campagne di comunicazione.

Correlazioni: Chimica + Demografica + Valutazione




L'estensione della matrice di correlazione alle variabili demografiche e alla valutazione offre due indicazioni strategiche fondamentali. La variabile **eta** mostra correlazioni praticamente nulle con tutte le caratteristiche chimiche (tutte comprese tra -0.05 e 0.01), indicando che i consumatori di età diverse non tendono a bere vini con composizioni chimiche sistematicamente diverse: l'età non è un predittore della tipologia di vino consumata, ma potrebbe influenzare l'intensità del giudizio espresso. La variabile **valutazione** mostra le correlazioni più significative con **sulphates** (0.34), **alcohol** (0.36) e — in direzione negativa — con **volatile.acidity** (-0.15): i vini con più alcol e solfiti tendono a ricevere valutazioni leggermente più alte, mentre un'acidità volatile elevata (tipicamente associata a difetti fermentativi) penalizza il giudizio. Questi segnali, seppur moderati, forniscono indicazioni concrete per le decisioni di formulazione della cantina biologica.

6 Analisi delle Valutazioni

6.1 Top Vini per Valutazione Media

Identificare i vini con le valutazioni più alte è il punto di partenza per capire quali profili chimici generano soddisfazione nei consumatori e, di conseguenza, quali pratiche di cantina è strategico valorizzare nella comunicazione del brand. Il filtro su almeno 3 recensioni elimina i vini con un numero di osservazioni troppo esiguo per essere statisticamente affidabili.



Il grafico a barre orizzontali mostra una gerarchia chiara: il **Nerello Mascalese Etna** si posiziona in testa con un punteggio medio di 7.58, seguito dal **Barolo DOCG** (7.37) e dalla **Ribolla Gialla** (7.30). La coda della classifica è occupata dal **Greco di Tufo** (5.74) e dal **Montepulciano d'Abruzzo** (5.81), con uno scarto di quasi 2 punti rispetto al podio — una differenza percettivamente significativa per i consumatori. Degno di nota è che i tre vini in testa appartengono a

denominazioni geograficamente distanti (Sicilia, Piemonte, Friuli–Venezia Giulia), suggerendo che la preferenza non è guidata dall’origine regionale bensì da caratteristiche intrinseche del profilo aromatico e tannico. Questa classifica costituisce la base per le decisioni di pricing premium e per l’allocazione delle risorse comunicative del brand.

6.2 Segmentazione per Fascia d’Età

La fascia d’età è una variabile di segmentazione classica nel marketing del vino. Definire fasce interpretabili (Ragazzo, Giovane, Adulto, Maturo, Anziano) consente di costruire messaggi di marca differenziati: i consumatori più giovani tendono a preferire vini freschi e fruttati, mentre le fasce mature apprezzano maggiormente la complessità tannica — caratteristica spesso esaltata dalla viticoltura biologica.


Table 3: Distribuzione per Fascia d’Età

Fascia	N	Percentuale
Ragazzo	293	14.7
Giovane	427	21.4
Adulto	152	7.6
Maturo	1014	50.7
Anziano	114	5.7

La tabella mostra una distribuzione fortemente sbilanciata verso la fascia **Maturo** (50–64 anni), che da sola rappresenta il 50.7% del campione con 1.014 recensioni. Seguono i **Giovani** (26–35 anni, 21.4%) e i **Ragazzi** (18–25 anni, 14.7%), mentre **Adulti** (36–50 anni, 7.6%) e **Anziani** (65+, 5.7%) risultano nettamente sottorappresentati. Questa distribuzione demografica ha implicazioni dirette per l’analisi statistica successiva: i test comparativi tra fasce dovranno tenere conto dello squilibrio campionario, e le conclusioni sulle fasce minori vanno interpretate con maggiore cautela data la minore potenza statistica. Dal punto di vista di business, il presidio dominante della fascia Maturo indica il target prioritario a cui orientare la comunicazione principale del brand.

Valutazione Media per Fascia d'Età

Barre di errore: ± 1 errore standard della media




Il grafico a barre con barre d'errore mostra che le valutazioni medie per fascia d'età sono notevolmente simili tra loro, tutte comprese in un range ristretto tra 6.54 (Maturo) e 6.70 (Ragazzo e Adulto). Le barre d'errore — che rappresentano ± 1 errore standard della media — si sovrappongono abbondantemente per tutte le fasce, indicando già visivamente che le differenze osservate potrebbero non raggiungere la significatività statistica. La fascia **Maturo** presenta la valutazione media lievemente più bassa (6.54), mentre **Ragazzo** e **Adulto** condividono il punteggio più alto (6.70): un pattern controintuitivo che verrà esaminato con rigore statistico nella sezione dei test. Questo grafico è utile come punto di partenza comunicativo per gli stakeholder, ma richiede la conferma statistica formale prima di tradursi in scelte di prodotto.

6.3 Boxplot delle Valutazioni per Fascia d'Età

Il boxplot integra il grafico delle medie mostrando la distribuzione completa: è utile per rilevare se le differenze tra fasce sono dovute a variazioni sistematiche o a singoli valori estremi — un'informazione cruciale per decidere se personalizzare la gamma di prodotti per segmento.

Distribuzione delle Valutazioni per Fascia d'Età

Ogni punto rappresenta una singola recensione



I boxplot mostrano che tutte le fasce d'età presentano una distribuzione delle valutazioni sostanzialmente simile, con mediane intorno a 6.5–7 e interquartili compresi tra circa 6 e 7.5. La forma delle distribuzioni è leggermente asimmetrica verso il basso per tutte le fasce, con code inferiori più allungate rispetto a quelle superiori — indicando che le valutazioni molto basse sono meno frequenti ma più disperse rispetto a quelle alte. I punti outlier (in bordeaux) sono presenti soprattutto nella fascia **Maturo**, che è anche la più numerosa: questo è un effetto dimensionale atteso e non indica necessariamente comportamenti anomali. La sostanziale sovrapposizione dei boxplot tra le fasce conferma visivamente l'ipotesi che le preferenze in termini di qualità percepita non si differenziano in modo netto per età, preparando il terreno per la verifica statistica formale che segue.

7 Test Statistici sulle Fasce d'Età

7.1 ANOVA per fascia d'età

Prima di trarre conclusioni strategiche sulle differenze di preferenza tra fasce d'età, è necessario verificarne la significatività statistica. L'ANOVA standard richiede normalità dei residui e omoschedasticità; la Welch ANOVA e il Kruskal-Wallis forniscono risultati robusti anche quando queste assunzioni non sono soddisfatte — una garanzia fondamentale con dataset di dimensioni reali e distribuzioni asimmetriche.

```
## === ANOVA STANDARD (FASCIA D'ETA') ===
```

```

##              Df Sum Sq Mean Sq F value Pr(>F)
## fascia_eta    4    9.2   2.302   2.227 0.0639 .
## Residuals  1995 2062.7   1.034
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

##
## === SHAPIRO-WILK SUI RESIDUI (campione casuale) ===

##
## Shapiro-Wilk normality test
##
## data:  residui_campione
## W = 0.99084, p-value = 6.493e-10

##
## === BARTLETT: OMOSCHEDASTICITÀ ===

##
## Bartlett test of homogeneity of variances
##
## data:  valutazione by fascia_eta
## Bartlett's K-squared = 18.273, df = 4, p-value = 0.001092

##
## === WELCH ANOVA (robusta alle varianze diseguali) ===

##
## One-way analysis of means (not assuming equal variances)
##
## data:  valutazione and fascia_eta
## F = 2.2866, num df = 4.00, denom df = 447.05, p-value = 0.05927

##
## === KRUSKAL-WALLIS (non parametrico) ===

##
## Kruskal-Wallis rank sum test
##
## data:  valutazione by fascia_eta
## Kruskal-Wallis chi-squared = 10.901, df = 4, p-value = 0.0277

```

I risultati diagnostici mostrano che le assunzioni fondamentali dell'ANOVA standard non sono rispettate dai dati analizzati. Il test di Shapiro-Wilk sui residui (p-value < 0.001) e il test di Bartlett sulle varianze (p-value = 0.001) respingono fermamente le ipotesi di normalità e di varianze omogenee. A causa di queste violazioni, il risultato marginale dell'ANOVA classica (p-value

= 0.0639) non può essere considerato statisticamente affidabile. Affidandosi al test non parametrico di Kruskal-Wallis, idoneo per distribuzioni non normali, emerge una differenza statisticamente significativa tra le fasce d'età (p-value = 0.0277). Questa evidenza statistica convalida l'ipotesi che l'apprezzamento del vino vari significativamente in base all'età del recensore, fornendo una base solida per la differenziazione delle strategie di marketing.

7.2 ANOVA per nazionalità

L'esecuzione di test statistici multipli sulla variabile geografica serve a verificare se le differenze di valutazione tra le varie nazionalità sono statisticamente significative. Procedere con questo test permette di accertare l'affidabilità dell'ANOVA standard, controllando preventivamente le assunzioni matematiche di normalità e omoschedasticità.

```
## === ANOVA STANDARD (NAZIONALITÀ) ===

##              Df Sum Sq Mean Sq F value Pr(>F)
## nazionalita    3   15.3   5.097   4.947 0.00201 **
## Residuals  1996 2056.7   1.030
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

##
## === SHAPIRO-WILK SUI RESIDUI (campione casuale) ===

##
## Shapiro-Wilk normality test
##
## data:  residui_campione_naz
## W = 0.99285, p-value = 2.696e-08

##
## === BARTLETT: OMOSCHEDASTICITÀ ===

##
## Bartlett test of homogeneity of variances
##
## data:  valutazione by nazionalita
## Bartlett's K-squared = 6.4153, df = 3, p-value = 0.09306

##
## === WELCH ANOVA (robusta alle varianze diseguali) ===

##
## One-way analysis of means (not assuming equal variances)
##
## data:  valutazione and nazionalita
## F = 4.9688, num df = 3.00, denom df = 845.01, p-value = 0.00201
```

```
##
## === KRUSKAL-WALLIS (non parametrico) ===

##
## Kruskal-Wallis rank sum test
##
## data:  valutazione by nazionalita
## Kruskal-Wallis chi-squared = 14.628, df = 3, p-value = 0.002164
```

I risultati diagnostici indicano che l'assunzione di normalità dei residui è chiaramente violata, dato che il test di Shapiro-Wilk restituisce un p-value ampiamente inferiore alla soglia di significatività. Tuttavia, il test di Bartlett (p-value = 0.093) suggerisce che l'assunzione di omoschedasticità è rispettata, non fornendo evidenze sufficienti per rigettare l'ipotesi di varianze uguali nei sottogruppi. A causa della non normalità dei dati, è metodologicamente corretto fare affidamento sul test non parametrico di Kruskal-Wallis. Quest'ultimo conferma in modo inequivocabile (p-value = 0.002) la presenza di una differenza statisticamente significativa nelle valutazioni espresse dalle diverse nazionalità. Questa evidenza statistica convalida l'ipotesi che l'origine geografica del consumatore influenzi attivamente la percezione e l'apprezzamento del vino, fornendo una base empirica solida per la differenziazione delle strategie di esportazione.

7.3 Confronti Post-Hoc (Tukey HSD)

Il test di Tukey identifica quali coppie specifiche di fasce d'età presentano valutazioni significativamente diverse. Questi risultati sono direttamente azionabili: se Ragazzi e Anziani mostrano preferenze significativamente diverse, la cantina può sviluppare due linee di comunicazione distinte, ognuna valorizzando le caratteristiche del vino più apprezzate dal rispettivo segmento.


```
## === TUKEY HSD: CONFRONTI MULTIPLI ===

## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = valutazione ~ fascia_eta, data = dataset)
##
## $fascia_eta
##              diff          lwr          upr          p adj
## Giovane-Ragazzo -0.047869492 -0.2584782 0.16273918 0.9718367
## Adulto-Ragazzo  -0.007409736 -0.2849220 0.27010250 0.9999936
## Maturo-Ragazzo  -0.161385652 -0.3455234 0.02275206 0.1175937
## Anziano-Ragazzo -0.095129034 -0.4015854 0.21132738 0.9156221
## Adulto-Giovane   0.040459756 -0.2217575 0.30267703 0.9934221
## Maturo-Giovane  -0.113516160 -0.2736772 0.04664486 0.2989733
## Anziano-Giovane -0.047259542 -0.3399375 0.24541841 0.9921719
## Maturo-Adulto    -0.153975916 -0.3954476 0.08749579 0.4089602
## Anziano-Adulto  -0.087719298 -0.4316923 0.25625369 0.9573378
## Anziano-Maturo   0.066256618 -0.2079898 0.34050299 0.9648552
```

I risultati del test evidenziano che nessuna delle coppie di fasce d'età analizzate presenta differenze statisticamente significative nelle valutazioni. Tutti i valori della colonna p adj (p-value aggiustato) sono ampiamente superiori alla soglia canonica di 0.05. La discrepanza più rilevabile, relativa al confronto tra i segmenti “Maturo” e “Ragazzo”, si ferma infatti a un p-value di 0.117. Questo esito è coerente con il risultato marginale dell'ANOVA standard (p-value = 0.0639) e chiarisce che, al netto delle variazioni globali rilevate dai test non parametrici, non emergono divergenze a coppie sufficientemente estreme. Questo suggerisce che le preferenze dei consumatori sfumano gradualmente da una generazione all'altra senza spaccature nette, indicando che la cantina non dovrebbe sviluppare prodotti esclusivi e polarizzati per specifiche età, ma piuttosto adattare le sfumature della comunicazione.

7.4 Diagnostica del Modello ANOVA

I grafici diagnostici — residui vs valori adattati e Q-Q plot — verificano visivamente le assunzioni del modello lineare. La loro interpretazione integra i test formali e consente di comunicare agli stakeholder il livello di fiducia riposto nelle conclusioni statistiche.



Il pannello sinistro (Residui vs Valori Adattati) mostra che i residui si distribuiscono in bande verticali distinte, corrispondenti ai cinque valori adattati discreti del modello (uno per ciascuna fascia d'età): questo pattern a “colonne” è strutturale quando la variabile dipendente assume solo valori interi o semi-interi, come la scala di valutazione utilizzata. La linea rossa di tendenza è sostanzialmente piatta, confermando l'assenza di pattern sistematici nella varianza dei residui che comprometterebbero le inferenze. Il pannello destro (Q-Q plot) mostra code che si discostano dalla retta teorica sia nella parte inferiore che in quella superiore, confermando la deviazione dalla

normalità già evidenziata dallo Shapiro-Wilk. Questa diagnostica visiva rinforza la decisione di affidarsi al Kruskal-Wallis come test principale per le conclusioni strategiche.

8 Regressione Lineare e Multicollinearità

8.1 Modello Completo

La regressione lineare con tutte le variabili chimiche e demografiche come predittori permette di rispondere a una domanda chiave: *quali caratteristiche del vino e del consumatore spiegano la valutazione?* Per una cantina biologica, scoprire che un basso livello di solfiti o un'acidità bilanciata predicono valutazioni più alte sarebbe una conferma scientifica del valore del metodo biologico.

```
##
## Call:
## lm(formula = valutazione ~ ., data = dataset_reg)
##
## Residuals:
```

	Min	1Q	Median	3Q	Max
	-2.94513	-0.58608	0.02284	0.58713	2.76332

```
##
## Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.5092424	9.5198226	-0.369	0.71245
fixed.acidity	0.0535007	0.0297662	1.797	0.07243 .
volatile.acidity	-1.4534968	0.1974680	-7.361	2.67e-13 ***
citric.acid	0.3956262	0.1618573	2.444	0.01460 *
residual.sugar	0.0240895	0.0153214	1.572	0.11605
chlorides	-2.8192211	1.4140712	-1.994	0.04632 *
free.sulfur.dioxide	0.0097253	0.0030903	3.147	0.00167 **
total.sulfur.dioxide	-0.0016134	0.0007448	-2.166	0.03042 *
density	7.4666732	9.3990314	0.794	0.42705
pH	-0.1266141	0.2168892	-0.584	0.55944
sulphates	2.0840187	0.2582899	8.069	1.22e-15 ***
alcohol	0.2042785	0.0193971	10.531	< 2e-16 ***
eta	-0.0026377	0.0012652	-2.085	0.03721 *
sexoM	-0.0436776	0.0402319	-1.086	0.27777
nazionalitaFrancia	-0.2203325	0.0699217	-3.151	0.00165 **
nazionalitaItalia	-0.0708816	0.0597866	-1.186	0.23593
nazionalitaUSA	0.0521844	0.0650777	0.802	0.42272
typeW	-0.0087403	0.1006746	-0.087	0.93083

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.883 on 1982 degrees of freedom
```

```
## Multiple R-squared:  0.2542, Adjusted R-squared:  0.2478
## F-statistic: 39.75 on 17 and 1982 DF,  p-value: < 2.2e-16
```

Il modello di regressione lineare include 17 predittori e spiega il **25.4%** della varianza nelle valutazioni (R^2 aggiustato = 0.248), con una significatività globale altamente robusta (F-statistic: 39.75, $p < 2.2e-16$). I predittori con impatto più forte e statisticamente significativo sono: **alcohol** (= +0.204, $p < 0.001$): ogni punto percentuale aggiuntivo di alcol aumenta la valutazione attesa di 0.2 punti — un segnale che i consumatori premiamo vini strutturati. **sulphates** (= +2.084, $p < 0.001$): i solfiti, usati con moderazione nel biologico, hanno un impatto positivo sulla qualità percepita, probabilmente come proxy della cura produttiva. **volatile.acidity** (= -1.453, $p < 0.001$): l'acidità volatile elevata penalizza fortemente la valutazione — conferma empirica che i difetti fermentativi sono percepiti negativamente. **free.sulfur.dioxide** (= +0.010, $p = 0.002$): l'anidride solforosa libera ha un effetto positivo piccolo ma significativo. Sul fronte demografico, i recensori francesi esprimono valutazioni significativamente più basse rispetto alla categoria di riferimento (= -0.220, $p = 0.002$) e l'età ha un effetto negativo minimo (= -0.003, $p = 0.037$): i consumatori più anziani tendono a esprimere giudizi leggermente più severi. Il sesso e la tipologia di vino (rosso/bianco) non risultano predittori significativi una volta controllate le caratteristiche chimiche.

8.2 Verifica della Multicollinearità (VIF)

La multicollinearità gonfia gli errori standard dei coefficienti, rendendo instabili le stime. Il VIF (Variance Inflation Factor) superiore a 5 è un segnale di allerta; superiore a 10 indica un problema serio che richiede la rimozione o l'aggregazione delle variabili collineari prima di interpretare i coefficienti.

```
## === GVIF AGGIUSTATO ===
##
##          GVIF Df  GVIF^(1/(2*Df))  GVIF_adj
## fixed.acidity      4.633806   1      2.152628  2.152628
## volatile.acidity    3.079589   1      1.754876  1.754876
## citric.acid         1.595822   1      1.263258  1.263258
## residual.sugar      3.183729   1      1.784301  1.784301
## chlorides           2.626998   1      1.620802  1.620802
## free.sulfur.dioxide  4.921731   1      2.218498  2.218498
## total.sulfur.dioxide 6.021674   1      2.453910  2.453910
## density             3.402759   1      1.844657  1.844657
## pH                  2.078550   1      1.441718  1.441718
## sulphates           2.479990   1      1.574799  1.574799
## alcohol             2.007187   1      1.416752  1.416752
## eta                 1.005986   1      1.002988  1.002988
## sesso               1.007026   1      1.003507  1.003507
## nazionalita         1.030180   3      1.004968  1.004968
## type                6.369277   1      2.523743  2.523743
##
## Predittori con VIF > 5:
## Predittori con VIF > 10:
```

L'analisi del GVIF aggiustato conferma un profilo di multicollinearità complessivamente contenuto. Nessun predittore supera la soglia critica di $VIF > 10$ che richiederebbe un intervento obbligatorio. I valori più elevati appartengono a `total.sulfur.dioxide` (GVIF_adj 2.45) e `type` (GVIF_adj 2.52), entrambi superiori a 2 ma abbondantemente sotto la soglia di allerta di 5. Questa situazione è coerente con quanto già osservato nella matrice di correlazione: le due variabili sui solfiti (libero e totale) condividono parte dell'informazione, ma non a un livello tale da compromettere la stabilità delle stime. Il modello di regressione può quindi essere interpretato con fiducia, senza necessità di eliminare o aggregare predittori per ragioni di multicollinearità.

8.3 Selezione del Modello con Stepwise AIC

La selezione stepwise bidirezionale (direzione “both”) parte dal modello completo e valuta a ogni passo se aggiungere o rimuovere un predittore migliora il criterio AIC (Akaike Information Criterion). A differenza del VIF — che segnala multicollinearità ma non indica quali variabili mantenere — lo stepwise produce direttamente il sottoinsieme di predittori che massimizza il compromesso tra bontà di adattamento e parsimonia del modello. Per una cantina biologica, un modello più parsimonioso è anche più comunicabile: permette di affermare con chiarezza quali caratteristiche del vino e del consumatore influenzano la valutazione, senza il rumore di variabili ridondanti.

```
##
## === MODELLO FINALE DOPO STEPWISE AIC ===

##
## Call:
## lm(formula = valutazione ~ fixed.acidity + volatile.acidity +
##      citric.acid + residual.sugar + chlorides + free.sulfur.dioxide +
##      total.sulfur.dioxide + sulphates + alcohol + eta + nazionalita,
##      data = dataset_reg)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.92631 -0.58844  0.03237  0.58470  2.78417
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    3.5906259   0.2358847   15.222 < 2e-16 ***
## fixed.acidity    0.0586772   0.0266554    2.201 0.027828 *
## volatile.acidity -1.5260213   0.1745198   -8.744 < 2e-16 ***
## citric.acid      0.3656797   0.1535960    2.381 0.017369 *
## residual.sugar   0.0286809   0.0127116    2.256 0.024161 *
## chlorides       -3.0363241   1.3476730   -2.253 0.024367 *
## free.sulfur.dioxide 0.0081580   0.0022445    3.635 0.000285 ***
## total.sulfur.dioxide -0.0018602 0.0005421   -3.432 0.000612 ***
## sulphates        2.0601567   0.2318426    8.886 < 2e-16 ***
## alcohol          0.2026263   0.0187630   10.799 < 2e-16 ***
## eta             -0.0026505   0.0012639   -2.097 0.036114 *
## nazionalitaFrancia -0.2179513   0.0698394   -3.121 0.001830 **
```

```
## nazionalitaItalia      -0.0712303  0.0597102  -1.193  0.233038
## nazionalitaUSA         0.0493305  0.0650102   0.759  0.448055
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8825 on 1986 degrees of freedom
## Multiple R-squared:  0.2534, Adjusted R-squared:  0.2486
## F-statistic: 51.86 on 13 and 1986 DF,  p-value: < 2.2e-16

##
## === VARIABILI RIMOSSE DALLO STEPWISE ===

## density
## pH
## sessoM
## typeW
```

Il modello selezionato dallo stepwise AIC include 13 predittori e risulta statisticamente significativo nel suo complesso ($F = 51.86$, $p < 2.2e-16$). Il ΔAIC di 5.84 rispetto al modello completo conferma la bontà della selezione: le variabili **density**, **pH**, **sesso** e **type** sono state eliminate in quanto non apportavano potere esplicativo aggiuntivo.

I predittori chimici di maggiore impatto sulla valutazione sono **volatile.acidity** (effetto negativo, $= -1.53$) e **sulphates** (effetto positivo, $= +2.06$), coerentemente con le aspettative enologiche. Tra le variabili demografiche, i consumatori francesi mostrano una valutazione sistematicamente inferiore ($= -0.22$), suggerendo aspettative di prodotto più selettive in quel mercato.

L' R^2 aggiustato si attesta a 0.249, indicando che il modello spiega circa il 25% della varianza nelle valutazioni. Questo valore è nella norma per modelli di preferenza sensoriale, dove fattori contestuali non osservabili — abbinamento gastronomico, aspettative individuali, occasione di consumo — contribuiscono strutturalmente alla variabilità residua. Il modello è pertanto da interpretarsi come uno strumento di analisi dei driver di soddisfazione piuttosto che come un sistema predittivo ad alta precisione.

9 Graduatorie dei Vini per Fascia d'Età

La creazione di graduatorie specifiche per segmento demografico è uno strumento di business intelligence immediato. Una cantina che sa che i vini X e Y sono i preferiti dai consumatori maturi può orientare le strategie di distribuzione, pricing e comunicazione in modo preciso ed efficiente, senza sprecare risorse su messaggi generici.

```
##
## === TOP 10 VINI - FASCIA: RAGAZZO ===
## # A tibble: 10 x 5
```

```
##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Barolo DCG      7.49              40 Ragazzo      1
##  2 Ribolla Gialla  7.46              12 Ragazzo      2
##  3 Nerello Mascalese Etna 7.44              8 Ragazzo      3
##  4 Vermentino di Gallura 7.36              11 Ragazzo      4
##  5 Brunello di Montalcino 7.21              12 Ragazzo      5
##  6 Barbera d'Asti  7.14              14 Ragazzo      6
##  7 Cannonau di Sardegna 6.72              16 Ragazzo      7
##  8 Soave Classico  6.68              36 Ragazzo      8
##  9 Primitivo di Manduria 6.6              5 Ragazzo      9
## 10 Fiano di Avellino 6.57              14 Ragazzo     10
```

```
##
```

```
## === TOP 10 VINI - FASCIA: GIOVANE ===
```

```
## # A tibble: 10 x 5
```

```
##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Nerello Mascalese Etna 7.62              16 Giovane      1
##  2 Barolo DCG      7.30              57 Giovane      2
##  3 Barbera d'Asti  7.11              14 Giovane      3
##  4 Ribolla Gialla  7              28 Giovane      4
##  5 Vermentino di Gallura 6.84              22 Giovane      5
##  6 Cannonau di Sardegna 6.81              13 Giovane      6
##  7 Soave Classico  6.81              39 Giovane      7
##  8 Brunello di Montalcino 6.77              15 Giovane      8
##  9 Fiano di Avellino 6.70              22 Giovane      9
## 10 Chianti Classico 6.65              17 Giovane     10
```

```
##
```

```
## === TOP 10 VINI - FASCIA: ADULTO ===
```

```
## # A tibble: 10 x 5
```

```
##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Nerello Mascalese Etna 8.25              8 Adulto      1
##  2 Ribolla Gialla  7.44              9 Adulto      2
##  3 Brunello di Montalcino 7.3              5 Adulto      3
##  4 Barolo DCG      7.29             19 Adulto      4
##  5 Soave Classico  6.94             16 Adulto      5
##  6 Fiano di Avellino 6.93              7 Adulto      6
##  7 Vermentino di Gallura 6.86              7 Adulto      7
##  8 Sagrantino di Montefalco 6.83              3 Adulto      8
##  9 Barbera d'Asti  6.81              8 Adulto      9
## 10 Amarone della Valpolicella 6.5              7 Adulto     10
```

```
##
```

```
## === TOP 10 VINI - FASCIA: MATURO ===
```

```
## # A tibble: 10 x 5
```

```
##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Nerello Mascalese Etna 7.47             32 Maturo      1
```

```
## 2 Ribolla Gialla          7.44          49 Maturo          2
## 3 Barolo DCG             7.38         108 Maturo          3
## 4 Barbera d'Asti          7.18          38 Maturo          4
## 5 Vermentino di Gallura   6.80          41 Maturo          5
## 6 Brunello di Montalcino  6.74          23 Maturo          6
## 7 Cannonau di Sardegna   6.62          36 Maturo          7
## 8 Sagrantino di Montefalco 6.60          38 Maturo          8
## 9 Fiano di Avellino       6.57          56 Maturo          9
## 10 Verdicchio dei Castelli 6.56          50 Maturo         10
##
```

```
## === TOP 10 VINI - FASCIA: ANZIANO ===
```

```
## # A tibble: 10 x 5
```

```
##   id_vino          valutazione_media n_recensioni fascia  posizione
##   <chr>           <dbl>           <int> <chr>      <int>
## 1 Cannonau di Sardegna      8.5             3 Anziano      1
## 2 Fiano di Avellino         7.62            4 Anziano      2
## 3 Barbera d'Asti            7.5             3 Anziano      3
## 4 Primitivo di Manduria      7.5             4 Anziano      4
## 5 Barolo DCG                7.25            10 Anziano      5
## 6 Vermentino di Gallura      7.2             5 Anziano      6
## 7 Nerello Mascalese Etna     7.17            3 Anziano      7
## 8 Ribolla Gialla            7.11            9 Anziano      8
## 9 Brunello di Montalcino     6.88            8 Anziano      9
## 10 Falanghina del Sannio     6.64            7 Anziano     10
```

Le graduatorie segmentate rivelano pattern di preferenza coerenti e alcune specificità per fascia degne di attenzione strategica. Il **Nerello Mascalese Etna** e il **Barolo DCG** emergono come vini di eccellenza trasversali: compaiono nelle prime posizioni in tutte le fasce d'età, suggerendo che il loro profilo organolettico ha un appeal universale che la cantina dovrebbe capitalizzare nella comunicazione principale. La **Ribolla Gialla** conferma la sua forza anche tra i consumatori più giovani (2° posto nella fascia Ragazzo), mentre il **Brunello di Montalcino** scala le posizioni con l'aumentare dell'età del recensore — un pattern tipico dei vini con complessità tannica apprezzata dai palati più esperti. La fascia **Anziano** presenta la graduatoria più volatile (campione di 114 recensioni), con il **Cannonau di Sardegna** in cima con un punteggio medio di 8.5 su soli 3 recensori: questo dato va interpretato con cautela e richiede l'acquisizione di ulteriori osservazioni prima di tradursi in decisioni di posizionamento. Queste graduatorie sono direttamente utilizzabili come input per la pianificazione delle degustazioni mirate e per la costruzione di bundle di prodotti personalizzati per fascia demografica.

10 Clustering dei Vini

10.1 Standardizzazione e Selezione delle Feature

La standardizzazione (z-score) è un prerequisito non negoziabile per k-means. Senza di essa, variabili con unità di misura diverse (es. `total.sulfur.dioxide` in mg/L vs pH adimensionale) dominereb-

bero il calcolo delle distanze, rendendo il clustering di fatto insensibile alle variabili con scala ridotta. Per una cantina biologica, un clustering affidabile dei vini consente di identificare le “famiglie” di prodotti e di costruire una narrazione di gamma coerente.

Si tracciano gli indici delle righe valide (prive di NA) per garantire l’allineamento corretto tra il risultato del clustering e il dataframe originale `vini_clean` nelle fasi successive.

```
## Righe usate per il clustering vini: 20
```

```
## Feature utilizzate: 11
```

```
## Variabili: fixed.acidity, volatile.acidity, citric.acid, residual.sugar, chlorides, free.sul
```

Tutti i 20 vini del catalogo sono disponibili per il clustering, utilizzando l’intero set di 11 caratteristiche chimiche standardizzate. La standardizzazione porta ogni variabile a media 0 e deviazione standard 1, garantendo che l’alcol (scala 8–14%), i solfiti (scala 10–300 mg/L) e il pH (scala 3.1–3.7) contribuiscano equamente al calcolo delle distanze euclidee tra i profili chimici.


10.2 Selezione del Numero Ottimale di Cluster (k) per i vini

Utilizzare tre criteri complementari — R^2 , Silhouette e Pseudo-F — riduce il rischio di scegliere un k sub-ottimale basandosi su un solo indicatore. Il criterio del gomito sull’ R^2 indica quando l’aggiunta di un cluster porta un guadagno marginale decrescente; la Silhouette misura la coesione interna e la separazione tra cluster; lo Pseudo-F premia le soluzioni in cui la varianza inter-cluster è massima rispetto a quella intra-cluster.

##	k	R2	pseudoF	silhouette
## 1	2	0.2672274	6.564237	0.1908865
## 2	3	0.3798424	5.206193	0.1175987
## 3	4	0.4757260	4.839464	0.1416125
## 4	5	0.5463939	4.517085	0.1290893
## 5	6	0.6040143	4.270962	0.1522533
## 6	7	0.6571484	4.152881	0.1441169
## 7	8	0.7070089	4.136696	0.1417252
## 8	9	0.7528644	4.188748	0.1504342
## 9	10	0.7941595	4.286811	0.1610603

Metriche per la Selezione di k — Clustering Vini

Scegliere il k nel gomito dell'Elbow (R^2), al picco della Silhouette e dello Pseudo-F



Il grafico a tre pannelli mostra l'andamento delle metriche al variare di k da 2 a 10. Il pannello **Pseudo-F** presenta il picco marcato in corrispondenza di $k = 2$, con una caduta ripida fino a $k = 8$ e una leggera risalita successiva: questo suggerisce che la separazione inter-cluster è massima per una bipartizione semplice, ma il guadagno si riduce rapidamente aggiungendo cluster. Il pannello **R^2** mostra la curva di saturazione classica dell'elbow method: il guadagno marginale è maggiore da $k = 2$ a $k = 3$ (da 0.27 a 0.38), si riduce progressivamente e tende ad appiattirsi oltre $k = 6$, indicando $k = 3$ come punto di equilibrio tra complessità e potere esplicativo. Il pannello **Silhouette** presenta un andamento irregolare tipico dei dataset piccoli, con un picco in $k = 2$ (0.191) e valori generalmente bassi che suggeriscono sovrapposizioni nei profili chimici — atteso con soli 20 osservazioni e 11 dimensioni. I tre criteri non convergono su un unico valore ottimale: la Gap Statistic fornisce il verdetto formale.

La Gap Statistic fornisce un riferimento formale basato su simulazione Monte Carlo: confronta la varianza intra-cluster osservata con quella attesa sotto un'ipotesi nulla di distribuzione uniforme dei dati. È particolarmente utile quando i tre criteri empirici non convergono sullo stesso valore di k.

```
## === GAP STATISTIC - VINI ===
```

```
##          logW    E.logW          gap    SE.sim
## [1,] 3.075606 3.127958 0.052351670 0.04107596
## [2,] 2.901351 2.935192 0.033840846 0.03862665
## [3,] 2.792180 2.806355 0.014174555 0.04139638
## [4,] 2.681961 2.691084 0.009122951 0.04323466
## [5,] 2.575453 2.578392 0.002939066 0.04540621
```

```
##
```


```
## Il numero ottimale di cluster (k) calcolato tramite Gap Statistic è: 3
```

La Gap Statistic indica $k = 3$ come numero ottimale di cluster per i vini, applicando la regola di Tibshirani che seleziona il k più piccolo la cui Gap è entro 1 SE dalla Gap del k successivo. Questo risultato è coerente con il gomito visivo nell' R^2 e rappresenta un numero di famiglie interpretabile dal punto di vista enologico: tre linee di prodotto distinte offrono sufficiente differenziazione senza frammentare eccessivamente il catalogo di 20 etichette. Il valore $k = 3$ viene adottato come scelta definitiva per il clustering gerarchico che segue.

10.3 Clustering Gerarchico

Con soli 20 vini e 11 variabili chimiche, il rapporto osservazioni/variabili è troppo basso per garantire stabilità al k -means standard. Si adottano due accorgimenti: una riduzione dimensionale via PCA prima del clustering (per eliminare il rumore nelle distanze), e il clustering gerarchico come risultato primario — più affidabile con dataset piccoli perché non richiede di specificare k a priori e produce gruppi verificabili visivamente.

```
## Componenti PCA che spiegano 80% della varianza: 5
```



La PCA ha concentrato l'80% della varianza nelle prime **5 componenti principali**, riducendo lo spazio da 11 a 5 dimensioni e attenuando il rumore nelle distanze euclidee inter-vino. Il dendrogramma risultante mostra una struttura gerarchica chiara, con due macro-rami principali che si separano a una distanza di Ward elevata (circa 10): questo indica una distinzione netta tra due grandi famiglie chimiche nel catalogo. All'interno del ramo destro (vini 4, 11 in bordeaux + 8 vini in arancione) si distingue un ulteriore sottogruppo coeso a bassa distanza interna, mentre i due vini isolati in verde (posizioni 13 e 17) formano un micro-cluster autonomo per la loro composizione chimica peculiare. Il taglio a $k = 3$ (come indicato dalla Gap Statistic) produce i cluster descritti nella sezione successiva.

Distribuzione cluster vini (gerarchico su PCA):

```
##
##  1  2  3
## 10  8  2
```

##

Vini per cluster:

Cluster 1 (10 vini): Nero d'Avola Riserva, Primitivo di Manduria, Chianti Classico, Brunello

Cluster 2 (8 vini): Amarone della Valpolicella, Barbera d'Asti, Sagrantino di Montefalco, Gr

Cluster 3 (2 vini): Vermentino di Gallura, Soave Classico


Il taglio del dendrogramma a $k = 3$ produce tre cluster di dimensioni asimmetriche: il **Cluster 1** è il più numeroso (10 vini) e raggruppa etichette prevalentemente rosse e strutturate come il Nero d'Avola, il Brunello e il Cannonau; il **Cluster 2** conta 8 vini e include denominazioni come l'Amarone, la Barbera e il Sagrantino; il **Cluster 3** è il più ristretto (2 vini) e isola il Vermentino di Gallura e il Soave Classico — entrambi vini bianchi leggeri con profilo aromatico distinto dagli altri. Questa distribuzione conferma che il catalogo biologico è dominato da vini rossi strutturati (18 su 20), con soli due bianchi sufficientemente diversi chimicamente da formare una famiglia autonoma.

10.4 Heatmap Cluster Vini

La heatmap dei profili chimici normalizzati permette di leggere in modo immediato i tratti distintivi di ciascun cluster e di costruire la narrativa di posizionamento per ciascuna linea di prodotto.

Heatmap dei Profili Chimici per Cluster

Valori ed etichette normalizzati per riga (Z-Score)



La heatmap, con valori normalizzati per riga (Z-Score), rende immediatamente leggibili le peculiarità chimiche di ciascun cluster. Il **Cluster “Corposi • Alto alcol”** si distingue per il valore Z più alto su **chlorides** (+1.15) e **sulphates** (+1.04), con **alcohol** elevato (+0.89) e **pH** basso (-1.15): un profilo tipico di vini rossi concentrati, con una struttura minerale importante e buona longevità. Il **Cluster “Leggeri • Bianchi”** mostra i valori Z più alti su **free.sulfur.dioxide** (+1.15) e **total.sulfur.dioxide** (+0.96), con **density** elevata (+0.67) e **alcohol** basso (-1.08): coerente con il profilo dei vini bianchi aromatici e freschi che richiedono maggiore protezione solforosa. Il **Cluster “Ricchi • Aromatici”** occupa una posizione intermedia, con **residual.sugar** leggermente più alto (+0.67 nella variante normalizzata) e **density** bassa (-1.15): un cluster di vini rossi con corpo medio e note fruttate più pronunciate. Questi tre profili si traducono in tre posizionamenti di mercato distinti: vini da invecchiamento per i Corposi, vini da aperitivo e abbinamento leggero per i Bianchi, vini da pasto versatile per gli Aromatici.

10.5 Profilazione dei Cluster di Vini

La profilazione assegna un'identità interpretabile a ciascun cluster, traducendo le medie delle variabili chimiche in caratteristiche enologiche comprensibili. Questo è il passaggio che trasforma un risultato algoritmico in un insight di business comunicabile — ad esempio: “Cluster 1: Corposi ad alto contenuto alcolico e basso residuo zuccherino”. La tabella seguente riporta i valori medi assoluti (non normalizzati) per ciascuna variabile chimica, utili per la comunicazione tecnica con i responsabili di cantina.

Table 4: Profilo Chimico Medio per Cluster di Vini (Clustering Gerarchico)

Variabile	Cluster 1_Corposi • Alto alcol	Cluster 2_Ricchi • Aromatici	Cluster 3_Leggeri • Bianchi
fixed.acidity	9.459	7.099	6.865
volatile.acidity	0.575	0.378	0.410
citric.acid	0.243	0.376	0.225
residual.sugar	4.154	4.624	4.085
chlorides	0.084	0.046	0.045
free.sulfur.dioxide	21.625	28.050	56.335
total.sulfur.dioxide	69.482	125.299	170.610
density	0.999	1.000	0.990
pH	3.267	3.383	3.400
sulphates	0.605	0.525	0.560
alcohol	11.178	9.984	10.750

La tabella di profilazione conferma le interpretazioni della heatmap con valori assoluti. Il cluster **“Corposi • Alto alcol”** ha il tenore alcolico medio più alto (11.18%), la **fixed.acidity** più elevata (9.46) e il **pH** più basso (3.27): un profilo che richiama la struttura dei grandi vini rossi meridionali. Il cluster **“Leggeri • Bianchi”** si distingue per i valori estremi di **free.sulfur.dioxide** (56.3 mg/L) e **total.sulfur.dioxide** (170.6 mg/L), con la **density** più bassa (0.990) e l'alcol intermedio (10.75%): il profilo tipico dei bianchi aromatici a bassa densità. Il cluster **“Ricchi • Aromatici”** si posiziona nel mezzo per la maggior parte delle variabili, con il **residual.sugar** leggermente superiore (4.62 g/L) e **free.sulfur.dioxide** intermedio (28.1 mg/L). Questi profili medi sono direttamente utilizzabili dal responsabile di cantina per calibrare i processi produttivi futuri in modo da rafforzare le identità chimiche di ciascuna famiglia.

11 Clustering dei Consumatori (Recensori)

11.1 Preparazione delle Feature dei Consumatori

Una segmentazione robusta dei consumatori richiede di sfruttare **tutte le variabili demografiche e comportamentali disponibili**, non solo le numeriche continue. In questo dataset le variabili utili sono: **età** (continua), **valutazione** (comportamentale, continua), **sex** (categorica binaria) e **nationalita** (categorica nominale).

Le variabili categoriche vengono trasformate in dummy binarie tramite `model.matrix` con contrasti di trattamento (k-1 dummy per fattore, dove la categoria di riferimento è il primo livello alfabetico). Tutte le colonne risultanti vengono poi standardizzate con z-score prima del clustering, per garantire che nessuna variabile domini il calcolo delle distanze euclidee in virtù della sua scala. Si tracciano gli indici delle righe valide per consentire la corretta restituzione delle etichette di cluster al dataframe originale nelle fasi successive.

```
## Righe usate per il clustering consumatori: 2000
```

```
## Feature originali: 2 → dopo encoding: 2 colonne
```

```
## Colonne generate: età, valutazione
```


Tutti i 2.000 recensori sono disponibili per il clustering, con le due variabili principali `età` e `valutazione` come feature di segmentazione. La scelta di utilizzare queste due dimensioni permette di individuare segmenti definiti sia dall'anagrafica del consumatore sia dal suo comportamento di giudizio — le due leve più direttamente azionabili per le strategie di marketing personalizzato.

11.2 Selezione del k Ottimale per i Consumatori

Lo stesso approccio multi-criterio usato per i vini viene applicato ai consumatori. Massimizzare la Silhouette garantisce che i segmenti individuati siano internamente coesi e reciprocamente distinti: condizione necessaria affinché le campagne di marketing personalizzate abbiano un target definito e non si sovrappongano.

##	k	R2	pseudoF	silhouette
## 1	2	0.4532778	1656.507	0.4732334
## 2	3	0.6811611	2133.175	0.4890173
## 3	4	0.7828351	2398.391	0.4863406
## 4	5	0.8357341	2537.486	0.4590055
## 5	6	0.8659354	2575.886	0.4491621
## 6	7	0.8901546	2691.782	0.4374255
## 7	8	0.9037111	2670.819	0.4345875
## 8	9	0.9148701	2674.600	0.4164201
## 9	10	0.9216565	2601.217	0.4228174

Metriche per la Selezione di k — Clustering Consumatori



Per i consumatori, le metriche mostrano un comportamento più regolare rispetto ai vini, grazie alla dimensionalità ridotta (2 feature) e alla maggiore numerosità del campione (2.000 osservazioni). Il pannello **Pseudo-F** presenta una crescita fino a $k = 7$ con un plateau successivo, suggerendo che la separazione inter-cluster continua a migliorare ma con rendimenti decrescenti oltre $k = 4-5$. Il pannello **R²** segue la classica curva di saturazione, con un guadagno marcato da $k = 2$ (0.45) a $k = 3$ (0.68) e progressivamente minore a k superiori: il gomito è visibile tra $k = 3$ e $k = 4$. Il pannello **Silhouette** mostra il valore più alto in $k = 3$ (0.489), con una caduta netta oltre $k = 4$: questo è il criterio più informativo per dataset con struttura cluster ben definita e punta chiaramente a **$k = 3$** come scelta ottimale. I tre criteri convergono su $k = 3$, segnale di robustezza della segmentazione.

Come per i vini, la Gap Statistic offre un controllo formale indipendente dai criteri empirici, confermando o suggerendo di rivedere il k individuato dalla Silhouette.

=== GAP STATISTIC - CONSUMATORI ===

```
##          logW    E.logW          gap          SE.sim
## [1,] 6.791634 7.293396 0.5017621 0.006615390
## [2,] 6.431017 7.000963 0.5699469 0.007127413
## [3,] 6.159342 6.793388 0.6340454 0.006376064
## [4,] 5.979995 6.600173 0.6201779 0.007114976
## [5,] 5.847332 6.497970 0.6506378 0.005795305
```

```
##
```

```
## Il numero ottimale di cluster (k) calcolato tramite Gap Statistic è: 3
```

La Gap Statistic conferma $k = 3$ come numero ottimale di cluster per i consumatori, allineandosi con la convergenza già osservata negli indici empirici. I valori di Gap crescono monotonicamente da $k = 1$ a $k = 5$ (da 0.50 a 0.65), ma la regola di Tibshirani identifica $k = 3$ come il punto di equilibrio tra semplicità del modello e qualità della segmentazione. Tre cluster di consumatori rappresentano una granularità ottimale per la gestione operativa: abbastanza fini da costruire strategie differenziate, abbastanza ampi da essere gestiti con risorse di marketing limitate.

11.3 Profilazione dei Cluster di Consumatori

La profilazione arricchisce l’etichetta numerica del cluster con le caratteristiche medie del segmento: età, comportamento di valutazione, composizione di genere e nazionalità prevalente. Questo passaggio è essenziale per dare un nome di business ai cluster (es. “Giovani donne con alta propensione alla valutazione”) e per costruire campagne di comunicazione mirate, coerenti con l’identità etica del brand.

Table 5: Profilo dei Cluster di Consumatori

cluster_km	eta_media	valutazione_media	n_recensioni	cluster_label
1	57.8	5.775	715	Adulti — Bassa valutazione
3	27.5	6.709	755	Giovani — Valutazione media
2	57.6	7.584	530	Adulti — Alta valutazione


La tabella di profilazione rivela tre segmenti di consumatori con caratteristiche ben distinte. Il segmento “**Adulti — Bassa valutazione**” (715 recensori, età media 57.8 anni) esprime giudizi sistematicamente inferiori (media 5.78): si tratta di consumatori maturi e probabilmente più esigenti o abituati a standard elevati, che potrebbero essere avvicinati con comunicazioni che enfatizzano il metodo produttivo biologico e la certificazione.

Il segmento “**Giovani — Valutazione media**” (755 recensori, età media 27.5 anni) è il più numeroso e assegna valutazioni medie (6.71): rappresenta il core target per azioni di brand awareness sui canali digitali, dove la giovane età e la propensione all’esplorazione si traducono in opportunità di fidelizzazione precoce.

Il segmento “**Adulti — Alta valutazione**” (530 recensori, età media 57.6 anni) è il più favorevole al brand (media 7.58) pur condividendo l’età media con il cluster a bassa valutazione: questa distinzione suggerisce che la variabile età da sola non è sufficiente a spiegare il comportamento di valutazione, e che fattori comportamentali (es. frequenza di acquisto, esperienza pregressa con vini biologici) giocano un ruolo determinante.

12 Analisi Integrata: Cluster di Vini e Preferenze dei Consumatori

Incrociare i cluster dei vini con i cluster dei consumatori rivela quale segmento di prodotti è più apprezzato da quale specifico profilo di clientela. Questo insight è direttamente utilizzabile per costruire bundle di prodotti, campagne mirate e strategie di upselling coerenti con i valori etici del brand. Solo i vini e i consumatori con un cluster assegnato vengono inclusi nell'analisi, preservando la coerenza del join.



La heatmap di incrocio cluster × cluster è lo strumento più direttamente azionabile dell'intera analisi. Le celle più scure (valori più alti) indicano le combinazioni prodotto-consumatore più performanti, e il pattern emergente è chiaro: il segmento **“Adulti — Alta valutazione”** premia tutti

e tre i cluster di vini con punteggi sopra 7.4, confermando che si tratta di consumatori genuinamente soddisfatti dal portafoglio biologico, indipendentemente dalla tipologia.

Il segmento “**Adulti — Bassa valutazione**” assegna voti inferiori a tutti i cluster di vino (range 5.72–5.97), con una preferenza relativa verso i “**Ricchi • Aromatici**” (5.97): questo cluster è il candidato prioritario per azioni di up-education, come degustazioni guidate che spieghino il valore aggiunto del metodo biologico.


Il segmento “**Giovani — Valutazione media**” mostra la preferenza più marcata per i vini “**Corposi • Alto alcol**” (6.81) e “**Ricchi • Aromatici**” (6.83), suggerendo che i giovani consumatori apprezzano la struttura e la complessità aromatica, mentre i “**Leggeri • Bianchi**” ottengono il punteggio più basso da questa fascia (6.50). Questa mappa strategica orienta direttamente le decisioni di abbinamento prodotto-canale: i vini corposi vanno comunicati ai giovani sui social, gli aromatici ai consumatori adulti critici come leva di riconquista, i bianchi leggeri ai consumatori alta valutazione come premium experience.

13 Visualizzazioni di Sintesi per la Dashboard

Le due visualizzazioni seguenti sono state progettate specificamente per essere replicate in Power BI o Tableau come grafici interattivi di primo livello nella dashboard esecutiva. Offrono una sintesi visiva immediata dei due principali risultati dell’analisi — la distribuzione dei cluster di consumatori e il portafoglio dei cluster di vini — e fungono da punto di ingresso per la navigazione approfondita nei dettagli.

Distribuzione dei Cluster di Consumatori


Dimensione, composizione demografica e comportamento di valori



Il grafico sintetizza in un colpo d'occhio la composizione e il comportamento di ciascun segmento di consumatori. I tre cluster presentano numerosità comparabili (530–755 recensori), segnale di una segmentazione equilibrata che non è dominata da un unico gruppo. Il segmento **“Adulti — Alta valutazione”** è il più prezioso in termini di customer equity: pur essendo il meno numeroso (530, 26.5%), esprime la valutazione media più alta (7.58) e può essere il vettore principale per il passaparola positivo e le recensioni online. La visualizzazione include età media e valutazione media direttamente nelle etichette, rendendola autosufficiente per la presentazione agli stakeholder senza necessità di tabelle aggiuntive.

Portafoglio Vini: Valutazione Media per Cluste

Ogni barra rappresenta un vino, colorato per cluster di appartenenza



Il grafico a barre orizzontali del portafoglio prodotti combina in un'unica visualizzazione la classifica per valutazione media e l'appartenenza al cluster chimico. Il colore di ogni barra indica il cluster: bordeaux per i **“Corposi • Alto alcol”**, rosso scuro per i **“Ricchi • Aromatici”** e ocra per i **“Leggeri • Bianchi”**. Emerge immediatamente che i vini con le valutazioni più alte appartengono prevalentemente ai cluster Corposi e Ricchi (Nerello Mascalese, Barolo, Ribolla Gialla, Barbera d'Asti), mentre i due bianchi leggeri (Vermentino e Soave) si collocano nella fascia media della classifica. Questa visualizzazione è il punto di partenza ideale per la costruzione del filtro interattivo nella dashboard: selezionando un cluster si filtrano automaticamente i vini corrispondenti e le metriche di valutazione aggiornate.

14 Export per Dashboard

14.1 Preparazione dei File di Export

L'export strutturato è il punto di connessione tra l'analisi in R e gli strumenti di Business Intelligence. I file prodotti sono progettati per essere importati direttamente in Power BI o Tableau senza trasformazioni aggiuntive, riducendo il tempo tra analisi e decisione strategica.

```
## === FILE ESPORTATI ===
```

```
## export_recensioni_cluster.csv → 2000 righe, 7 colonne
```

```
## export_dataset_unificato.csv → 2000 righe, 6 colonne
```

```
##
```

```
## Tutti i file sono codificati in UTF-8 e pronti per Power BI / Tableau.
```

I due file esportati coprono rispettivamente il livello consumatore (2.000 righe, arricchite con cluster e fascia d'età) e il livello integrato (dataset join tra vini e recensitori con le etichette cluster di entrambi). La codifica UTF-8 garantisce la corretta visualizzazione dei caratteri accentati italiani (nomi di vini e denominazioni) sia in Power BI che in Tableau, senza necessità di conversioni aggiuntive.

14.2 Riepilogo delle Variabili Chiave per la Dashboard

La tabella seguente funge da dizionario dati: indica per ciascun file esportato le variabili di maggiore rilevanza per la costruzione di filtri, assi, KPI e dimensioni nelle dashboard di Business Intelligence.

Table 6: Guida alle Variabili Chiave per la Dashboard

File	Variabile	Uso_in_Dashboard
export_recensioni_cluster.csv	cluster_km	Filtro/colore per segmento consumatore
export_recensioni_cluster.csv	fascia_eta_rec	Segmento demografico per confronto/analisi
export_recensioni_cluster.csv	valutazione	KPI principale: punteggio medio recensioni
export_dataset_unificato.csv	cluster	Filtro/colore per segmento vino
export_dataset_unificato.csv	fascia_eta	Segmento demografico (prodotto)
export_dataset_unificato.csv	valutazione	Cross-filtro prodotto × consumatore (valutazione)

Il dizionario dati facilita l'onboarding del team di BI che riceverà i file per la costruzione della dashboard, riducendo il rischio di utilizzo improprio delle variabili e garantendo coerenza interpretativa tra i due file esportati. In particolare, si segnala che la variabile **valutazione** compare in entrambi i file con lo stesso nome ma in contesti diversi: nel file recensioni è la singola valutazione grezza, nel dataset unificato è già aggregata per coppia cluster vino × cluster consumatore.

15 Conclusioni e Insight Strategici

L'analisi ha prodotto i seguenti risultati principali:

- **Qualità e Chimica dei Vini:** le distribuzioni delle variabili chimiche evidenziano profili distinti per tipologia di vino. La matrice di correlazione rivela coppie di variabili ridondanti (es. solfiti liberi/totali) che è opportuno monitorare nella formulazione dei prodotti biologici.

- **Segmentazione dei Vini:** il clustering gerarchico su PCA ha identificato 3 famiglie di vini con profili chimici omogenei: *Corposi* • *Alto alcol*, *Ricchi* • *Aromatici* e *Leggeri* • *Bianchi*. Ogni cluster corrisponde a una potenziale linea di prodotto con un posizionamento di mercato distinto e una narrazione di brand coerente.
- **Segmentazione dei Consumatori:** i consumatori si raggruppano in 3 cluster caratterizzati da combinazioni distinte di età e comportamento di valutazione: *Adulti — Alta valutazione*, *Giovani — Valutazione media* e *Adulti — Bassa valutazione*. Questi segmenti costituiscono la base per campagne di marketing personalizzate e coerenti con i valori etici del brand.
- **Preferenze Demografiche:** l'analisi integrata cluster $\times$ fascia d'età rivela quali famiglie di vini massimizzano la soddisfazione in ciascun segmento demografico, fornendo una mappa strategica per decisioni di prodotto, pricing e comunicazione. Il Kruskal-Wallis conferma che le differenze tra fasce d'età sono statisticamente significative ($p = 0.028$), mentre il test sulla nazionalità indica che anche l'origine geografica del consumatore influenza il giudizio ($p = 0.002$): due leve azionabili per la segmentazione delle campagne internazionali.

Prossimi Passi Raccomandati:

- Integrare dati di vendita per calcolare il Customer Lifetime Value per cluster di consumatori.
- Applicare modelli di raccomandazione (collaborative filtering) per personalizzare le proposte di acquisto.
- Estendere l'analisi con dati geografici per identificare pattern di preferenza per nazionalità a livello regionale.
- Sviluppare una dashboard interattiva in Power BI o Tableau utilizzando i file di export prodotti.

Report redatto dagli associati IT&BI Colombini Francesco & Lombardo Mattia - JEMIB Milano Bicocca 2026