

Analisi Business Intelligence — VinLiber

Customer Analytics, Clustering e Business Intelligence

Mattia Lombardo & Francesco Colombini

06 maggio 2026

Contents

1	Introduzione e Contesto di Business	3
2	Importazione e Qualità dei Dati	3
2.1	Caricamento dei Dataset	3
2.2	Report di Qualità dei Dati	3
2.3	Panoramica Statistica dei Dataset	4
3	Preprocessing e Gestione delle Anomalie	6
3.1	Rilevazione e Trattamento degli Outlier	6
3.2	Imputazione dei Valori Mancanti	7
4	Analisi Esplorativa dei Dati (EDA)	7
4.1	Distribuzione delle Caratteristiche Chimiche	7
4.2	Matrice di Correlazione tra Variabili Chimiche	8
4.3	Scatter Plot Matrix	9
5	Costruzione del Dataset Unificato	10
5.1	Join tra Vini e Recensioni	10
5.2	Correlazioni nel Dataset Unificato	11
6	Analisi delle Valutazioni	12
6.1	Top Vini per Valutazione Media	12
6.2	Segmentazione per Fascia d'Età	12
6.3	Boxplot delle Valutazioni per Fascia d'Età	13

7	Test Statistici sulle Fasce d'Età	14
7.1	ANOVA per fascia d'età	14
7.2	ANOVA per nazionalità	16
7.3	Confronti Post-Hoc (Tukey HSD)	17
7.4	Diagnostica del Modello ANOVA	18
8	Regressione Lineare e Multicollinearità	18
8.1	Modello Completo	18
8.2	Verifica della Multicollinearità (VIF)	19
9	Graduatorie dei Vini per Fascia d'Età	20
10	Clustering dei Vini	22
10.1	Standardizzazione e Selezione delle Feature	22
10.2	Selezione del Numero Ottimale di Cluster (k) per i vini	22
10.3	Clustering Gerarchico	24
10.4	Heatmap cluster vini	26
10.5	Profilazione dei Cluster di Vini	26
11	Clustering dei Consumatori (Recensori)	27
11.1	Preparazione delle Feature dei Consumatori	27
11.2	Selezione del k Ottimale per i Consumatori	27
11.3	Profilazione dei Cluster di Consumatori	29
12	Analisi Integrata: Cluster di Vini e Preferenze dei Consumatori	29
13	Export per Dashboard (Power BI / Tableau)	30
13.1	Preparazione dei File di Export	30
13.2	Riepilogo delle Variabili Chiave per la Dashboard	31
14	Conclusioni e Insight Strategici	31

1 Introduzione e Contesto di Business

Questa analisi supporta la strategia commerciale di una cantina focalizzata sulla **coltivazione biologica**, la **produzione etica** e il **valore sociale**. La viticoltura biologica si distingue da quella convenzionale per l'assenza di pesticidi di sintesi e per pratiche di conservazione del suolo che influenzano direttamente la composizione chimica del vino. Comprendere questi profili chimici — e come si traducono in preferenze di consumatori differenti — è il fondamento di una strategia di posizionamento autentica e sostenibile.

L'analisi si articola in quattro fasi principali:

1. **Qualità dei Dati e Preprocessing**: pulizia robusta e rilevazione di anomalie.
 2. **EDA Avanzata**: esplorazione delle correlazioni tra chimica del vino e preferenze demografiche.
 3. **Clustering**: segmentazione di vini e consumatori per profili omogenei.
 4. **Export per Dashboard**: produzione di file strutturati pronti per Power BI / Tableau.
-

2 Importazione e Qualità dei Dati

2.1 Caricamento dei Dataset

Il primo passo di qualsiasi pipeline professionale è verificare l'integrità dei dati prima di qualsiasi trasformazione. Per una cantina biologica, dove ogni lotto ha caratteristiche chimiche uniche legate alla stagione e al terroir, la presenza di duplicati o record orfani comprometterebbe la qualità degli insight estratti.

2.2 Report di Qualità dei Dati

Rilevare in modo esplicito i problemi di qualità — duplicati, chiavi orfane, valori mancanti — consente di documentare il livello di affidabilità dell'analisi e di comunicarlo in modo trasparente agli stakeholder aziendali.

```
## === REPORT QUALITÀ DATI ===
```

```
## --- Dataset VINI ---
```

```
## Righe totali:                20
```

```
## Colonne totali:             14
```

```
## Duplicati wine_id:          0
```

```
## NA in wine_id:              0
```

```
## Valori mancanti totali: 0

## --- Dataset RECENSIONI ---

## Righe totali: 2000

## Colonne totali: 5

## NA in wine_id: 0

## Valori mancanti totali: 0

## --- Integrità Referenziale ---

## Vini senza recensioni: 0

## Recensioni senza vino: 0
```

2.3 Panoramica Statistica dei Dataset

La funzione `skim_without_charts` produce un riassunto statistico compatto per ogni variabile: range, quantili, tasso di completezza e deviazione standard. Questo colpo d'occhio permette di individuare immediatamente le variabili con alta percentuale di NA o distribuzioni anomale prima di procedere con qualsiasi trasformazione.

```
## === SINTESI STATISTICA: VINI ===
```

Table 1: Data summary

Name	vini
Number of rows	20
Number of columns	14
Column type frequency:	
character	2
factor	1
numeric	11
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
wine_id	0	1	1	2	0	20	0
id_vino	0	1	9	26	0	20	0

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
type	0	1	FALSE	2	R: 12, W: 8

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100
fixed.acidity	0	1	8.25	1.47	5.47	6.91	8.15	9.67	10.21
volatile.acidity	0	1	0.48	0.20	0.16	0.36	0.49	0.57	0.97
citric.acid	0	1	0.29	0.16	0.00	0.21	0.32	0.39	0.60
residual.sugar	0	1	4.34	2.41	1.12	2.40	3.79	5.65	9.55
chlorides	0	1	0.06	0.03	0.03	0.05	0.06	0.08	0.11
free.sulfur.dioxide	0	1	27.72	12.81	10.64	18.22	26.21	31.47	61.44
total.sulfur.dioxide	0	1	102.82	70.47	27.98	43.89	73.84	154.07	294.11
density	0	1	1.00	0.00	0.99	1.00	1.00	1.00	1.00
pH	0	1	3.33	0.14	3.10	3.25	3.31	3.40	3.74
sulphates	0	1	0.57	0.13	0.24	0.49	0.58	0.63	0.79
alcohol	0	1	10.66	1.43	8.50	9.91	10.49	11.24	13.55

=== SINTESI STATISTICA: RECENSIONI ===

Table 2: Data summary

Name	recensioni
Number of rows	2000
Number of columns	5
Column type frequency:	
character	1
factor	2
numeric	2
Group variables	None

Variable type: character

skim_variable	n_missing	complete_rate	min	max	empty	n_unique	whitespace
wine_id	0	1	1	2	0	20	0

Variable type: factor

skim_variable	n_missing	complete_rate	ordered	n_unique	top_counts
secco	0	1	FALSE	2	M: 1173, F: 827
nazionalita	0	1	FALSE	4	Ita: 851, USA: 503, Fra: 350, Alt: 296

Variable type: numeric

skim_variable	n_missing	complete_rate	mean	sd	p0	p25	p50	p75	p100
età	0	1	46.32	15.66	20	29	54.0	60.0	69
valutazione	0	1	6.61	1.02	3	6	6.5	7.5	9

3 Preprocessing e Gestione delle Anomalie

3.1 Rilevazione e Trattamento degli Outlier

Gli outlier nei parametri chimici del vino (es. acidità volatile molto elevata, residuo zuccherino anomalo) non sono necessariamente errori: possono riflettere vini di nicchia con profili estremi. La strategia di Winsorizzazione scelta — che porta i valori oltre l'1° e il 99° percentile al limite stesso — preserva questi casi senza distorcere le analisi di clustering, che sono sensibili ai valori estremi su feature non scalate.

```
## fixed.acidity           → outlier corretti: basso=1, alto=1
## volatile.acidity       → outlier corretti: basso=0, alto=1
## citric.acid            → outlier corretti: basso=1, alto=1
## residual.sugar         → outlier corretti: basso=1, alto=1
## chlorides              → outlier corretti: basso=0, alto=0
## free.sulfur.dioxide    → outlier corretti: basso=1, alto=1
## total.sulfur.dioxide   → outlier corretti: basso=1, alto=1
## density                → outlier corretti: basso=0, alto=0
## pH                    → outlier corretti: basso=1, alto=1
## sulphates              → outlier corretti: basso=1, alto=1
## alcohol                → outlier corretti: basso=1, alto=1
```

3.2 Imputazione dei Valori Mancanti

Per le variabili chimiche continue si utilizza l'imputazione con la mediana anziché la media: la mediana è robusta rispetto agli outlier residui e non altera la distribuzione complessiva. Questa scelta è particolarmente indicata per dataset con code asimmetriche, comuni nelle misurazioni enochimiche, e garantisce che il clustering successivo non sia distorto da valori imputati non rappresentativi.

```
## NA prima dell'imputazione: 0  
## NA dopo l'imputazione:      0
```


4 Analisi Esplorativa dei Dati (EDA)

4.1 Distribuzione delle Caratteristiche Chimiche

I vini biologici tendono a presentare livelli di solfiti più bassi rispetto ai convenzionali, poiché la certificazione biologica limita l'uso di SO₂ aggiunta. Visualizzare la distribuzione di ciascuna variabile chimica per tipologia di vino permette di verificare empiricamente questo posizionamento e di comunicarlo con dati oggettivi.

Distribuzione delle Caratteristiche Chimiche per Tipologia di Vino


Ogni pannello mostra la distribuzione di una variabile chimica, distinta per tipo



4.2 Matrice di Correlazione tra Variabili Chimiche

La matrice di correlazione è uno strumento diagnostico fondamentale prima del clustering: variabili altamente correlate (come `free.sulfur.dioxide` e `total.sulfur.dioxide`) portano informazione ridondante e possono distorcere la distanza euclidea usata da k-means. Identificarle in anticipo consente di costruire un modello più preciso e interpretabile.


Correlazioni tra Variabili Chimiche



4.3 Scatter Plot Matrix

La visualizzazione a matrice di dispersione — con rette di regressione lineare sovrapposte — rivela relazioni non lineari che la sola correlazione di Pearson non cattura, come l'eventuale effetto a U dell'acidità sulla valutazione. Costituisce un complemento visivo alla matrice di correlazione numerica e aiuta a individuare cluster naturali già nella fase esplorativa.

Scatter Matrix — Variabili Chimiche dei Vini



5 Costruzione del Dataset Unificato

5.1 Join tra Vini e Recensioni


Il join interno (inner join) garantisce che solo i vini con almeno una recensione — e solo le recensioni associate a un vino nel catalogo — entrino nelle analisi successive. Questo preserva la coerenza referenziale ed è la scelta più conservativa per un dataset destinato a insight di business. Si crea inoltre l'alias `eta` per la variabile `età`, necessario per compatibilità con le formule R che non gestiscono caratteri accentati.

Dimensione dataset unificato: 2000 righe x 19 colonne

5.2 Correlazioni nel Dataset Unificato

Includere **eta** e **valutazione** nella matrice di correlazione permette di rispondere alla domanda chiave di business: le caratteristiche chimiche del vino che “piacciono di più” dipendono dall’età del consumatore? Questa analisi orienta sia la formulazione dei prodotti sia la segmentazione delle campagne di comunicazione.


Correlazioni: Chimica + Demografica + Valutazione



6 Analisi delle Valutazioni

6.1 Top Vini per Valutazione Media

Identificare i vini con le valutazioni più alte è il punto di partenza per capire quali profili chimici generano soddisfazione nei consumatori e, di conseguenza, quali pratiche di cantina è strategico valorizzare nella comunicazione del brand. Il filtro su almeno 3 recensioni elimina i vini con un numero di osservazioni troppo esiguo per essere statisticamente affidabili.




6.2 Segmentazione per Fascia d'Età

La fascia d'età è una variabile di segmentazione classica nel marketing del vino. Definire fasce interpretabili (Ragazzo, Giovane, Adulto, Maturo, Anziano) consente di costruire messaggi di marca differenziati: i consumatori più giovani tendono a preferire vini freschi e fruttati, mentre le fasce

mature apprezzano maggiormente la complessità tannica — caratteristica spesso esaltata dalla viticoltura biologica.

Table 3: Distribuzione per Fascia d'Età

Fascia	N	Percentuale
Ragazzo	293	14.7
Giovane	427	21.4
Adulto	152	7.6
Maturo	1014	50.7
Anziano	114	5.7




6.3 Boxplot delle Valutazioni per Fascia d'Età

Il boxplot integra il grafico delle medie mostrando la distribuzione completa: è utile per rilevare se le differenze tra fasce sono dovute a variazioni sistematiche o a singoli valori estremi — un'informazione cruciale per decidere se personalizzare la gamma di prodotti per segmento.

Distribuzione delle Valutazioni per Fascia d'Età

Ogni punto rappresenta una singola recensione



7 Test Statistici sulle Fasce d'Età

7.1 ANOVA per fascia d'età

Prima di trarre conclusioni strategiche sulle differenze di preferenza tra fasce d'età, è necessario verificarne la significatività statistica. L'ANOVA standard richiede normalità dei residui e omoschedasticità; la Welch ANOVA e il Kruskal-Wallis forniscono risultati robusti anche quando queste assunzioni non sono soddisfatte — una garanzia fondamentale con dataset di dimensioni reali e distribuzioni asimmetriche.

```
## === ANOVA STANDARD (FASCIA D'ETA')===
```

```
##           Df Sum Sq Mean Sq F value Pr(>F)
## fascia_eta    4    9.2   2.302   2.227 0.0639 .
## Residuals 1995 2062.7   1.034
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## === SHAPIRO-WILK SUI RESIDUI (campione casuale) ===
```

```

##
## Shapiro-Wilk normality test
##
## data:  residui_campione
## W = 0.99084, p-value = 6.493e-10

##
## === BARTLETT: OMOSCHEDASTICITÀ ===

##
## Bartlett test of homogeneity of variances
##
## data:  valutazione by fascia_eta
## Bartlett's K-squared = 18.273, df = 4, p-value = 0.001092

##
## === WELCH ANOVA (robusta alle varianze diseguali) ===

##
## One-way analysis of means (not assuming equal variances)
##
## data:  valutazione and fascia_eta
## F = 2.2866, num df = 4.00, denom df = 447.05, p-value = 0.05927

##
## === KRUSKAL-WALLIS (non parametrico) ===

##
## Kruskal-Wallis rank sum test
##
## data:  valutazione by fascia_eta
## Kruskal-Wallis chi-squared = 10.901, df = 4, p-value = 0.0277

```

I risultati diagnostici mostrano che le assunzioni fondamentali dell'ANOVA standard non sono rispettate dai dati analizzati. Il test di Shapiro-Wilk sui residui ($p\text{-value} < 0.001$) e il test di Bartlett sulle varianze ($p\text{-value} = 0.001$) respingono fermamente le ipotesi di normalità e di varianze omogenee. A causa di queste violazioni, il risultato marginale dell'ANOVA classica ($p\text{-value} = 0.0639$) non può essere considerato statisticamente affidabile. Affidandosi al test non parametrico di Kruskal-Wallis, idoneo per distribuzioni non normali, emerge una differenza statisticamente significativa tra le fasce d'età ($p\text{-value} = 0.0277$). Questa evidenza statistica convalida l'ipotesi che l'apprezzamento del vino vari significativamente in base all'età del recensore, fornendo una base solida per la differenziazione delle strategie di marketing.

7.2 ANOVA per nazionalità

L'esecuzione di test statistici multipli sulla variabile geografica serve a verificare se le differenze di valutazione tra le varie nazionalità sono statisticamente significative. Procedere con questo test permette di accertare l'affidabilità dell'ANOVA standard, controllando preventivamente le assunzioni matematiche di normalità e omoschedasticità.

```
## === ANOVA STANDARD (NAZIONALITÀ) ===

##           Df Sum Sq Mean Sq F value Pr(>F)
## nazionalita    3   15.3    5.097    4.947 0.00201 **
## Residuals  1996 2056.7    1.030
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

##
## === SHAPIRO-WILK SUI RESIDUI (campione casuale) ===

##
## Shapiro-Wilk normality test
##
## data:  residui_campione_naz
## W = 0.99285, p-value = 2.696e-08

##
## === BARTLETT: OMOSCHEDASTICITÀ ===

##
## Bartlett test of homogeneity of variances
##
## data:  valutazione by nazionalita
## Bartlett's K-squared = 6.4153, df = 3, p-value = 0.09306

##
## === WELCH ANOVA (robusta alle varianze diseguali) ===

##
## One-way analysis of means (not assuming equal variances)
##
## data:  valutazione and nazionalita
## F = 4.9688, num df = 3.00, denom df = 845.01, p-value = 0.00201

##
## === KRUSKAL-WALLIS (non parametrico) ===
```



```
##
## Kruskal-Wallis rank sum test
##
## data:  valutazione by nazionalita
## Kruskal-Wallis chi-squared = 14.628, df = 3, p-value = 0.002164
```

I risultati diagnostici indicano che l'assunzione di normalità dei residui è chiaramente violata, dato che il test di Shapiro-Wilk restituisce un p-value ampiamente inferiore alla soglia di significatività. Tuttavia, il test di Bartlett (p-value = 0.093) suggerisce che l'assunzione di omoschedasticità è rispettata, non fornendo evidenze sufficienti per rigettare l'ipotesi di varianze uguali nei sottogruppi. A causa della non normalità dei dati, è metodologicamente corretto fare affidamento sul test non parametrico di Kruskal-Wallis. Quest'ultimo conferma in modo inequivocabile (p-value = 0.002) la presenza di una differenza statisticamente significativa nelle valutazioni espresse dalle diverse nazionalità. Questa evidenza statistica convalida l'ipotesi che l'origine geografica del consumatore influenzi attivamente la percezione e l'apprezzamento del vino, fornendo una base empirica solida per la differenziazione delle strategie di esportazione.

7.3 Confronti Post-Hoc (Tukey HSD)

Il test di Tukey identifica quali coppie specifiche di fasce d'età presentano valutazioni significativamente diverse. Questi risultati sono direttamente azionabili: se Ragazzi e Anziani mostrano preferenze significativamente diverse, la cantina può sviluppare due linee di comunicazione distinte, ognuna valorizzando le caratteristiche del vino più apprezzate dal rispettivo segmento.

```
## === TUKEY HSD: CONFRONTI MULTIPLI ===


## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = valutazione ~ fascia_eta, data = dataset)
##
## $fascia_eta
##              diff          lwr          upr      p adj
## Giovane-Ragazzo -0.047869492 -0.2584782 0.16273918 0.9718367
## Adulto-Ragazzo  -0.007409736 -0.2849220 0.27010250 0.9999936
## Maturo-Ragazzo  -0.161385652 -0.3455234 0.02275206 0.1175937
## Anziano-Ragazzo -0.095129034 -0.4015854 0.21132738 0.9156221
## Adulto-Giovane   0.040459756 -0.2217575 0.30267703 0.9934221
## Maturo-Giovane  -0.113516160 -0.2736772 0.04664486 0.2989733
## Anziano-Giovane -0.047259542 -0.3399375 0.24541841 0.9921719
## Maturo-Adulto   -0.153975916 -0.3954476 0.08749579 0.4089602
## Anziano-Adulto  -0.087719298 -0.4316923 0.25625369 0.9573378
## Anziano-Maturo   0.066256618 -0.2079898 0.34050299 0.9648552
```

I risultati del test evidenziano che nessuna delle coppie di fasce d'età analizzate presenta differenze statisticamente significative nelle valutazioni. Tutti i valori della colonna p adj (p-value aggiustato)

sono ampiamente superiori alla soglia canonica di 0.05. La discrepanza più rilevabile, relativa al confronto tra i segmenti “Maturo” e “Ragazzo”, si ferma infatti a un p-value di 0.117. Questo esito è coerente con il risultato marginale dell’ANOVA standard (p-value = 0.0639) e chiarisce che, al netto delle variazioni globali rilevate dai test non parametrici, non emergono divergenze a coppie sufficientemente estreme. Questo suggerisce che le preferenze dei consumatori sfumano gradualmente da una generazione all’altra senza spaccature nette, indicando che la cantina non dovrebbe sviluppare prodotti esclusivi e polarizzati per specifiche età, ma piuttosto adattare le sfumature della comunicazione.

7.4 Diagnostica del Modello ANOVA

I grafici diagnostici — residui vs valori adattati e Q-Q plot — verificano visivamente le assunzioni del modello lineare. La loro interpretazione integra i test formali e consente di comunicare agli stakeholder il livello di fiducia riposto nelle conclusioni statistiche.



8 Regressione Lineare e Multicollinearità

8.1 Modello Completo

La regressione lineare con tutte le variabili chimiche e demografiche come predittori permette di rispondere a una domanda chiave: *quali caratteristiche del vino e del consumatore spiegano la*

valutazione? Per una cantina biologica, scoprire che un basso livello di solfiti o un'acidità bilanciata predicono valutazioni più alte sarebbe una conferma scientifica del valore del metodo biologico.

```
##
## Call:
## lm(formula = valutazione ~ ., data = dataset_reg)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.94513 -0.58608  0.02284  0.58713  2.76332
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -3.5092424   9.5198226  -0.369   0.71245
## fixed.acidity     0.0535007   0.0297662   1.797   0.07243 .
## volatile.acidity  -1.4534968   0.1974680  -7.361 2.67e-13 ***
## citric.acid       0.3956262   0.1618573   2.444   0.01460 *
## residual.sugar    0.0240895   0.0153214   1.572   0.11605
## chlorides        -2.8192211   1.4140712  -1.994   0.04632 *
## free.sulfur.dioxide  0.0097253   0.0030903   3.147   0.00167 **
## total.sulfur.dioxide -0.0016134   0.0007448  -2.166   0.03042 *
## density          7.4666732   9.3990314   0.794   0.42705
## pH              -0.1266141   0.2168892  -0.584   0.55944
## sulphates        2.0840187   0.2582899   8.069 1.22e-15 ***
## alcohol          0.2042785   0.0193971  10.531 < 2e-16 ***
## eta            -0.0026377   0.0012652  -2.085   0.03721 *
## sessoM          -0.0436776   0.0402319  -1.086   0.27777
## nazionalitaFrancia -0.2203325   0.0699217  -3.151   0.00165 **
## nazionalitaItalia  -0.0708816   0.0597866  -1.186   0.23593
## nazionalitaUSA      0.0521844   0.0650777   0.802   0.42272
## typeW           -0.0087403   0.1006746  -0.087   0.93083
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.883 on 1982 degrees of freedom
## Multiple R-squared:  0.2542, Adjusted R-squared:  0.2478
## F-statistic: 39.75 on 17 and 1982 DF,  p-value: < 2.2e-16
```

8.2 Verifica della Multicollinearità (VIF)

La multicollinearità gonfia gli errori standard dei coefficienti, rendendo instabili le stime. Il VIF (Variance Inflation Factor) superiore a 5 è un segnale di allerta; superiore a 10 indica un problema serio che richiede la rimozione o l'aggregazione delle variabili collineari prima di interpretare i coefficienti.

```
## === GVIF AGGIUSTATO ===
##              GVIF Df GVIF^(1/(2*Df)) GVIF_adj
```

```
## fixed.acidity      4.633806  1      2.152628 2.152628
## volatile.acidity   3.079589  1      1.754876 1.754876
## citric.acid        1.595822  1      1.263258 1.263258
## residual.sugar     3.183729  1      1.784301 1.784301
## chlorides          2.626998  1      1.620802 1.620802
## free.sulfur.dioxide 4.921731  1      2.218498 2.218498
## total.sulfur.dioxide 6.021674  1      2.453910 2.453910
## density            3.402759  1      1.844657 1.844657
## pH                 2.078550  1      1.441718 1.441718
## sulphates          2.479990  1      1.574799 1.574799
## alcohol            2.007187  1      1.416752 1.416752
## eta                1.005986  1      1.002988 1.002988
## sesso              1.007026  1      1.003507 1.003507
## nazionalita        1.030180  3      1.004968 1.004968
## type               6.369277  1      2.523743 2.523743
##
## Predittori con VIF > 5:
## Predittori con VIF > 10:
```

9 Graduatorie dei Vini per Fascia d'Età

La creazione di graduatorie specifiche per segmento demografico è uno strumento di business intelligence immediato. Una cantina che sa che i vini X e Y sono i preferiti dai consumatori maturi può orientare le strategie di distribuzione, pricing e comunicazione in modo preciso ed efficiente, senza sprecare risorse su messaggi generici.

```
##
## === TOP 10 VINI - FASCIA: RAGAZZO ===
## # A tibble: 10 x 5
##   id_vino      valutazione_media n_recensioni fascia  posizione
##   <chr>          <dbl>          <int> <chr>      <int>
## 1 Barolo DCG      7.49            40 Ragazzo      1
## 2 Ribolla Gialla  7.46            12 Ragazzo      2
## 3 Nerello Mascalese Etna 7.44             8 Ragazzo      3
## 4 Vermentino di Gallura 7.36            11 Ragazzo      4
## 5 Brunello di Montalcino 7.21            12 Ragazzo      5
## 6 Barbera d'Asti    7.14            14 Ragazzo      6
## 7 Cannonau di Sardegna 6.72            16 Ragazzo      7
## 8 Soave Classico   6.68            36 Ragazzo      8
## 9 Primitivo di Manduria 6.6              5 Ragazzo      9
## 10 Fiano di Avellino 6.57            14 Ragazzo     10
##
## === TOP 10 VINI - FASCIA: GIOVANE ===
## # A tibble: 10 x 5
```

```

##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Nerello Mascalese Etna      7.62            16 Giovane      1
##  2 Barolo DOCG      7.30            57 Giovane      2
##  3 Barbera d'Asti      7.11            14 Giovane      3
##  4 Ribolla Gialla      7            28 Giovane      4
##  5 Vermentino di Gallura      6.84            22 Giovane      5
##  6 Cannonau di Sardegna      6.81            13 Giovane      6
##  7 Soave Classico      6.81            39 Giovane      7
##  8 Brunello di Montalcino      6.77            15 Giovane      8
##  9 Fiano di Avellino      6.70            22 Giovane      9
## 10 Chianti Classico      6.65            17 Giovane     10
##
## === TOP 10 VINI - FASCIA: ADULTO ===
## # A tibble: 10 x 5
##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Nerello Mascalese Etna      8.25             8 Adulto      1
##  2 Ribolla Gialla      7.44             9 Adulto      2
##  3 Brunello di Montalcino      7.3              5 Adulto      3
##  4 Barolo DOCG      7.29            19 Adulto      4
##  5 Soave Classico      6.94            16 Adulto      5
##  6 Fiano di Avellino      6.93             7 Adulto      6
##  7 Vermentino di Gallura      6.86             7 Adulto      7
##  8 Sagrantino di Montefalco      6.83             3 Adulto      8
##  9 Barbera d'Asti      6.81             8 Adulto      9
## 10 Amarone della Valpolicella      6.5              7 Adulto     10
##
## === TOP 10 VINI - FASCIA: MATURO ===
## # A tibble: 10 x 5
##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Nerello Mascalese Etna      7.47            32 Maturo      1
##  2 Ribolla Gialla      7.44            49 Maturo      2
##  3 Barolo DOCG      7.38           108 Maturo      3
##  4 Barbera d'Asti      7.18            38 Maturo      4
##  5 Vermentino di Gallura      6.80            41 Maturo      5
##  6 Brunello di Montalcino      6.74            23 Maturo      6
##  7 Cannonau di Sardegna      6.62            36 Maturo      7
##  8 Sagrantino di Montefalco      6.60            38 Maturo      8
##  9 Fiano di Avellino      6.57            56 Maturo      9
## 10 Verdicchio dei Castelli      6.56            50 Maturo     10
##
## === TOP 10 VINI - FASCIA: ANZIANO ===
## # A tibble: 10 x 5
##      id_vino      valutazione_media n_recensioni fascia  posizione
##      <chr>              <dbl>          <int> <chr>      <int>
##  1 Cannonau di Sardegna      8.5              3 Anziano      1

```

##	2	Fiano di Avellino	7.62	4	Anziano	2
##	3	Barbera d'Asti	7.5	3	Anziano	3
##	4	Primitivo di Manduria	7.5	4	Anziano	4
##	5	Barolo DCG	7.25	10	Anziano	5
##	6	Vermentino di Gallura	7.2	5	Anziano	6
##	7	Nerello Mascalese Etna	7.17	3	Anziano	7
##	8	Ribolla Gialla	7.11	9	Anziano	8
##	9	Brunello di Montalcino	6.88	8	Anziano	9
##	10	Falanghina del Sannio	6.64	7	Anziano	10

10 Clustering dei Vini

10.1 Standardizzazione e Selezione delle Feature

La standardizzazione (z-score) è un prerequisito non negoziabile per k-means. Senza di essa, variabili con unità di misura diverse (es. `total.sulfur.dioxide` in mg/L vs pH adimensionale) dominerebbero il calcolo delle distanze, rendendo il clustering di fatto insensibile alle variabili con scala ridotta. Per una cantina biologica, un clustering affidabile dei vini consente di identificare le “famiglie” di prodotti e di costruire una narrazione di gamma coerente.

Si tracciano gli indici delle righe valide (prive di NA) per garantire l'allineamento corretto tra il risultato del clustering e il dataframe originale `vini_clean` nelle fasi successive.

```
## Righe usate per il clustering vini: 20
```

```
## Feature utilizzate: 11
```

```
## Variabili: fixed.acidity, volatile.acidity, citric.acid, residual.sugar, chlorides, free.sul
```

10.2 Selezione del Numero Ottimale di Cluster (k) per i vini


Utilizzare tre criteri complementari — R^2 , Silhouette e Pseudo-F — riduce il rischio di scegliere un k sub-ottimale basandosi su un solo indicatore. Il criterio del gomito sull' R^2 indica quando l'aggiunta di un cluster porta un guadagno marginale decrescente; la Silhouette misura la coesione interna e la separazione tra cluster; lo Pseudo-F premia le soluzioni in cui la varianza inter-cluster è massima rispetto a quella intra-cluster.

```
##      k      R2  pseudoF silhouette
## 1  2  0.2672274  6.564237  0.1908865
## 2  3  0.3798424  5.206193  0.1175987
## 3  4  0.4757260  4.839464  0.1416125
## 4  5  0.5463939  4.517085  0.1290893
## 5  6  0.6040143  4.270962  0.1522533
```

```
## 6 7 0.6571484 4.152881 0.1441169
## 7 8 0.7070089 4.136696 0.1417252
## 8 9 0.7528644 4.188748 0.1504342
## 9 10 0.7941595 4.286811 0.1610603
```

Metriche per la Selezione di k — Clustering Vini

Scegliere il k nel gomito dell'Elbow (R^2), al picco della Silhouette e dello Pseudo-F



La Gap Statistic fornisce un riferimento formale basato su simulazione Monte Carlo: confronta la varianza intra-cluster osservata con quella attesa sotto un'ipotesi nulla di distribuzione uniforme dei dati. È particolarmente utile quando i tre criteri empirici non convergono sullo stesso valore di k.

```
## === GAP STATISTIC - VINI ===
```

```
##          logW  E.logW      gap  SE.sim
## [1,] 3.075606 3.127958 0.052351670 0.04107596
## [2,] 2.901351 2.935192 0.033840846 0.03862665
```

```
## [3,] 2.792180 2.806355 0.014174555 0.04139638
## [4,] 2.681961 2.691084 0.009122951 0.04323466
## [5,] 2.575453 2.578392 0.002939066 0.04540621
```


```
##
```

```
## Il numero ottimale di cluster (k) calcolato tramite Gap Statistic è: 3
```

10.3 Clustering Gerarchico

Con soli 20 vini e 11 variabili chimiche, il rapporto osservazioni/variabili è troppo basso per garantire stabilità al k-means standard. Si adottano due accorgimenti: una riduzione dimensionale via PCA prima del clustering (per eliminare il rumore nelle distanze), e il clustering gerarchico come risultato primario — più affidabile con dataset piccoli perché non richiede di specificare k a priori e produce gruppi verificabili visivamente.

```
## Componenti PCA che spiegano 80% della varianza: 5
```

Distribuzione cluster vini (gerarchico su PCA):

##

1 2 3

10 8 2

##


Vini per cluster:

Cluster 1 (10 vini): Nero d'Avola Riserva, Primitivo di Manduria, Chianti Classico, Brunello

Cluster 2 (8 vini): Amarone della Valpolicella, Barbera d'Asti, Sagrantino di Montefalco, Gr

Cluster 3 (2 vini): Vermentino di Gallura, Soave Classico

10.4 Heatmap cluster vini



10.5 Profilazione dei Cluster di Vini

La profilazione assegna un'identità interpretabile a ciascun cluster, traducendo le medie delle variabili chimiche in caratteristiche enologiche comprensibili. Questo è il passaggio che trasforma un risultato algoritmico in un insight di business comunicabile — ad esempio: “Cluster 1: Corposi ad alto contenuto alcolico e basso residuo zuccherino”. La heatmap normalizzata (z-score per riga) permette di confrontare visivamente i profili dei cluster anche per variabili con scale molto diverse.

Table 4: Profilo Chimico Medio per Cluster di Vini (Clustering Gerarchico)

Variabile	Cluster 1_Corposi • Alto alcol	Cluster 2_Ricchi • Aromatici	Cluster 3_Leggeri • Bianchi
-----------	--------------------------------	------------------------------	-----------------------------

fixed.acidity	9.459	7.099	6.865
volatile.acidity	0.575	0.378	0.410
citric.acid	0.243	0.376	0.225
residual.sugar	4.154	4.624	4.085
chlorides	0.084	0.046	0.045
free.sulfur.dioxide	21.625	28.050	56.335
total.sulfur.dioxide	69.482	125.299	170.610
density	0.999	1.000	0.990
pH	3.267	3.383	3.400
sulphates	0.605	0.525	0.560
alcohol	11.178	9.984	10.750

11 Clustering dei Consumatori (Recensori)

11.1 Preparazione delle Feature dei Consumatori

Una segmentazione robusta dei consumatori richiede di sfruttare **tutte le variabili demografiche e comportamentali disponibili**, non solo le numeriche continue. In questo dataset le variabili utili sono: **età** (continua), **valutazione** (comportamentale, continua), **sex** (categoria binaria) e **nationality** (categoria nominale).

Le variabili categoriche vengono trasformate in dummy binarie tramite `model.matrix` con contrasti di trattamento (k-1 dummy per fattore, dove la categoria di riferimento è il primo livello alfabetico). Tutte le colonne risultanti vengono poi standardizzate con z-score prima del clustering, per garantire che nessuna variabile domini il calcolo delle distanze euclidee in virtù della sua scala. Si tracciano gli indici delle righe valide per consentire la corretta restituzione delle etichette di cluster al dataframe originale nelle fasi successive.

```
## Righe usate per il clustering consumatori: 2000
```

```
## Feature originali: 2 → dopo encoding: 2 colonne
```

```
## Colonne generate: età, valutazione
```


11.2 Selezione del k Ottimale per i Consumatori

Lo stesso approccio multi-criterio usato per i vini viene applicato ai consumatori. Massimizzare la Silhouette garantisce che i segmenti individuati siano internamente coesi e reciprocamente distinti: condizione necessaria affinché le campagne di marketing personalizzate abbiano un target definito e non si sovrappongano.

```
##      k      R2  pseudoF silhouette
## 1    2 0.4532778 1656.507  0.4732334
```

```
## 2 3 0.6811611 2133.175 0.4890173
## 3 4 0.7828351 2398.391 0.4863406
## 4 5 0.8357341 2537.486 0.4590055
## 5 6 0.8659354 2575.886 0.4491621
## 6 7 0.8901546 2691.782 0.4374255
## 7 8 0.9037111 2670.819 0.4345875
## 8 9 0.9148701 2674.600 0.4164201
## 9 10 0.9216565 2601.217 0.4228174
```

Metriche per la Selezione di k — Clustering Consumatori



Come per i vini, la Gap Statistic offre un controllo formale indipendente dai criteri empirici, confermando o suggerendo di rivedere il k individuato dalla Silhouette.

```
## === GAP STATISTIC - CONSUMATORI ===
```

```
##          logW    E.logW      gap    SE.sim
```

```
## [1,] 6.791634 7.293396 0.5017621 0.006615390
## [2,] 6.431017 7.000963 0.5699469 0.007127413
## [3,] 6.159342 6.793388 0.6340454 0.006376064
## [4,] 5.979995 6.600173 0.6201779 0.007114976
## [5,] 5.847332 6.497970 0.6506378 0.005795305
```

```
##
```

```
## Il numero ottimale di cluster (k) calcolato tramite Gap Statistic è: 3
```

11.3 Profilazione dei Cluster di Consumatori


La profilazione arricchisce l’etichetta numerica del cluster con le caratteristiche medie del segmento: età, comportamento di valutazione, composizione di genere e nazionalità prevalente. Questo passaggio è essenziale per dare un nome di business ai cluster (es. “Giovani donne con alta propensione alla valutazione”) e per costruire campagne di comunicazione mirate, coerenti con l’identità etica del brand.

Table 5: Profilo dei Cluster di Consumatori

cluster_km	eta_media	valutazione_media	n_recensioni	cluster_label
1	57.8	5.775	715	Adulti — Bassa valutazione
3	27.5	6.709	755	Giovani — Valutazione media
2	57.6	7.584	530	Adulti — Alta valutazione

12 Analisi Integrata: Cluster di Vini e Preferenze dei Consumatori

Incrociare i cluster dei vini con i cluster dei consumatori rivela quale segmento di prodotti è più apprezzato da quale specifico profilo di clientela. [Inference] Questo insight è direttamente utilizzabile per costruire bundle di prodotti, campagne mirate e strategie di upselling coerenti con i valori etici del brand. Solo i vini e i consumatori con un cluster assegnato vengono inclusi nell’analisi, preservando la coerenza del join.



13 Export per Dashboard (Power BI / Tableau)

13.1 Preparazione dei File di Export

L'export strutturato è il punto di connessione tra l'analisi in R e gli strumenti di Business Intelligence. I file prodotti sono progettati per essere importati direttamente in Power BI o Tableau senza trasformazioni aggiuntive, riducendo il tempo tra analisi e decisione strategica.

Le coordinate PCA vengono restituite a `vini_clean` tramite un vettore inizializzato a NA e popolato agli indici delle righe valide — lo stesso approccio usato per l'assegnazione dei cluster — evitando così qualsiasi disallineamento di righe.

Vengono esportati tre file: - `export_vini_cluster.csv`: il catalogo vini arricchito con il cluster di appartenenza e le coordinate PCA. - `export_recensioni_cluster.csv`: le recensioni arricchite con il cluster consumatore e la fascia d'età. - `export_dataset_unificato.csv`: il dataset join completo, pronto per analisi cross-dimensionali.

```
## === FILE ESPORTATI ===
```

```
## export_recensioni_cluster.csv → 2000 righe, 7 colonne
```

```
## export_dataset_unificato.csv → 2000 righe, 6 colonne
```

```
##
```

```
## Tutti i file sono codificati in UTF-8 e pronti per Power BI / Tableau.
```

13.2 Riepilogo delle Variabili Chiave per la Dashboard

La tabella seguente funge da dizionario dati: indica per ciascun file esportato le variabili di maggiore rilevanza per la costruzione di filtri, assi, KPI e dimensioni nelle dashboard di Business Intelligence.

Table 6: Guida alle Variabili Chiave per la Dashboard

File	Variabile	Uso_in_Dashboard
<code>export_recensioni_cluster.csv</code>	<code>cluster_km</code>	Filtro/colore per segmento consumatore
<code>export_recensioni_cluster.csv</code>	<code>fascia_eta_rec</code>	Segmento demografico per confronto/analisi
<code>export_recensioni_cluster.csv</code>	<code>valutazione</code>	KPI principale: punteggio medio recensioni
<code>export_dataset_unificato.csv</code>	<code>cluster</code>	Filtro/colore per segmento vino
<code>export_dataset_unificato.csv</code>	<code>fascia_eta</code>	Segmento demografico (prodotto)
<code>export_dataset_unificato.csv</code>	<code>valutazione</code>	Cross-filtro prodotto × consumatore (valutazione)

14 Conclusioni e Insight Strategici

L'analisi ha prodotto i seguenti risultati principali:

Qualità e Chimica dei Vini: le distribuzioni delle variabili chimiche evidenziano profili distinti per tipologia di vino. La matrice di correlazione rivela coppie di variabili ridondanti (es. solfiti liberi/totali) che è opportuno monitorare nella formulazione dei prodotti biologici.

Segmentazione dei Vini: il clustering k-means ha identificato 3 famiglie di vini con profili chimici omogenei, costruite sull'intero set di 11 caratteristiche chimiche standardizzate. Ogni cluster corrisponde a una potenziale linea di prodotto con un posizionamento di mercato distinto.

Segmentazione dei Consumatori: i consumatori si raggruppano in 3 cluster caratterizzati da combinazioni distinte di età e comportamento di valutazione. L'impiego di tutte le variabili demografiche disponibili — con encoding appropriato delle variabili categoriche — produce segmenti

più informativi rispetto a un approccio limitato alle sole variabili continue. Questi segmenti costituiscono la base per campagne di marketing personalizzate e coerenti con i valori etici del brand.

Preferenze Demografiche: l'analisi integrata cluster $\times$ fascia d'età rivela quali famiglie di vini massimizzano la soddisfazione in ciascun segmento demografico, fornendo una mappa strategica per decisioni di prodotto, pricing e comunicazione.

Prossimi Passi Raccomandati:

- Integrare dati di vendita per calcolare il Customer Lifetime Value per cluster di consumatori.
- Applicare modelli di raccomandazione (collaborative filtering) per personalizzare le proposte di acquisto.
- Estendere l'analisi con dati geografici per identificare pattern di preferenza per nazionalità a livello regionale.
- Sviluppare una dashboard interattiva in Power BI o Tableau utilizzando i file di export prodotti.

Report redatto dagli associati IT&BI Colombini Francesco & Lombardo Mattia - JEMIB Milano Bicocca 2026